

# Análisis de Correlación Canónica

## Un Ejemplo

- **Gastos y características socio-económicas de las Familias**
- **variables:**
  - Gastos en Alimentación
  - Gastos en Vestidos
  - Gastos en Vivienda
  - Gastos en Transporte
  - Gastos en Sanidad
  - Gastos en Educación
  - .....
  - Número de miembros del hogar
  - Nivel de ingresos del hogar
  - Nivel de estudios del sustentador pral
  - Edad media de los miembros del hogar
  - Número de miembros mayores de edad
  - Numero de perceptores del hogar
  - .....
- **¿Existe alguna relación de dependencia entre los hábitos de consumo de los hogares y las características socio-económicas de los mismos?**

# Análisis de Correlación Canónica

## Objetivo

- Mediante regresión lineal univariante se trata de explicar una variable  $Y$ , (*variable dependiente, endógena o explicada*), a partir de varias variables  $X_1, X_2, \dots, X_p$ , (*variables independientes, exógenas o explicativas*), mediante una relación lineal, en el caso general, de la forma:

$$\hat{Y} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$$

o, si las variables estuviesen centradas en el origen:

$$\hat{Y} = \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$$

- El Análisis de Correlación Canónica trata de extender esta idea cuando, además del conjunto de variables exógenas  $\{X_1, X_2, \dots, X_p\}$  hay, no sólo una variable  $Y$ , sino un conjunto de variables endógenas  $\{Y_1, Y_2, \dots, Y_q\}$ , para lo que trata de encontrar unos coeficientes  $\alpha_1^{(k)}, \alpha_2^{(k)}, \dots, \alpha_q^{(k)}$  y  $\beta_1^{(k)}, \beta_2^{(k)}, \dots, \beta_p^{(k)}$ , que proporcionen las mejores relaciones de aproximación del tipo:

$$\alpha_1^{(k)} Y_1 + \alpha_2^{(k)} Y_2 + \dots + \alpha_q^{(k)} Y_q = Y^{(k)} \cong X^{(k)} = \beta_1^{(k)} X_1 + \beta_2^{(k)} X_2 + \dots + \beta_p^{(k)} X_p$$

# Análisis de Correlación Canónica

## Variables canónicas

- Notando por  $\alpha^{(k)}$  y  $\beta^{(k)}$  los correspondientes vectores columna de coeficientes que intervienen abajo, el problema del Análisis de Correlación Canónica será encontrar una serie de nuevas variables tipificadas e incorrelacionadas en cada uno de los dos grupos,  $Y^{(k)}$  y  $X^{(k)}$ , que llamaremos *variables canónicas*,

$$Y^{(k)} = \alpha^{(k)'} y = \alpha_1^{(k)} Y_1 + \alpha_2^{(k)} Y_2 + \dots + \alpha_q^{(k)} Y_q$$

$$X^{(k)} = \beta^{(k)'} x = \beta_1^{(k)} X_1 + \beta_2^{(k)} X_2 + \dots + \beta_p^{(k)} X_p$$

de forma que sea máxima su correlación en términos absolutos (el cuadrado del coeficiente de correlación lineal):

$$\text{Max } \rho^2(Y^{(k)}, X^{(k)})$$

# Análisis de Correlación Canónica

## Cálculo de la primera pareja de variables canónicas

- Notas previas:
  - Al ser centradas las variables  $Y_1, Y_2, \dots, Y_q$  y  $X_1, X_2, \dots, X_p$ , lo serán en consecuencia las nuevas variables canónicas y, ya que son combinaciones lineales sin términos independientes de las anteriores
  - La matriz de varianzas y covarianzas de las variables toma la forma:

$$\Sigma = E[(x; y)(x; y)'] = E \begin{bmatrix} xx' & xy' \\ yx' & yy' \end{bmatrix} = \begin{pmatrix} E[xx'] & E[xy'] \\ E[yx'] & E[yy'] \end{pmatrix} = \begin{pmatrix} \Sigma_x & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_y \end{pmatrix}$$

- Y al exigirles como condición que se encuentren tipificadas e incorrelacionadas, estaremos imponiendo las siguientes condiciones sobre los respectivos parámetros:

$$\text{Var}(Y^{(k)}) = 1 \Leftrightarrow E[(\alpha^{(k)'} y)(\alpha^{(k)'} y)'] = \alpha^{(k)'} E[yy'] \alpha^{(k)} = 1 \Leftrightarrow \alpha^{(k)'} \Sigma_y \alpha^{(k)} = 1$$

$$\text{Cov}(Y^{(l)}, Y^{(k)}) = 0 \Leftrightarrow E[(\alpha^{(l)'} y)(\alpha^{(k)'} y)'] = \alpha^{(l)'} E[yy'] \alpha^{(k)} = 0 \Leftrightarrow \alpha^{(l)'} \Sigma_y \alpha^{(k)} = 0, \quad l \neq k$$

$$\text{Var}(X^{(k)}) = 1 \Leftrightarrow E[(\beta^{(k)'} x)(\beta^{(k)'} x)'] = \beta^{(k)'} E[xx'] \beta^{(k)} = 1 \Leftrightarrow \beta^{(k)'} \Sigma_x \beta^{(k)} = 1$$

$$\text{Cov}(X^{(l)}, X^{(k)}) = 0 \Leftrightarrow E[(\beta^{(l)'} x)(\beta^{(k)'} x)'] = \beta^{(l)'} E[xx'] \beta^{(k)} = 0 \Leftrightarrow \beta^{(l)'} \Sigma_x \beta^{(k)} = 0, \quad l \neq k$$

# Análisis de Correlación Canónica

## Cálculo de la primera pareja de variables canónicas

- El coeficiente de correlación lineal de Fisher para las primeras variables canónicas será:

$$\rho^2(X, Y) = \frac{Cov^2(Y, X)}{Var(Y) \cdot Var(X)} = \frac{E^2[(\alpha' y)(\beta' x)]}{(\alpha' \Sigma_y \alpha)(\beta' \Sigma_x \beta)} = \frac{(\alpha' E[yx'] \beta)^2}{(\alpha' \Sigma_y \alpha)(\beta' \Sigma_x \beta)} = \frac{(\alpha' \Sigma_{yx} \beta)^2}{(\alpha' \Sigma_y \alpha)(\beta' \Sigma_x \beta)}$$

- por lo que el problema de obtener las primeras variables canónicas puede expresarse como sigue:

\* Encontrar  $\alpha$  y  $\beta$  tales que :  $Var(Y) = Var(X) = 1$  y  $\rho^2(X, Y)$  sea máximo

o equivalentemente:

$$\text{Maximizar } (\alpha' \Sigma_{yx} \beta)^2 \quad \text{sueto a las restricciones: } \begin{cases} \alpha' \Sigma_y \alpha = 1 \\ \beta' \Sigma_x \beta = 1 \end{cases}$$

# Análisis de Correlación Canónica

## Cálculo de la primera pareja de variables canónicas

$$L = (\alpha' \Sigma_{yx} \beta)^2 - \lambda (\alpha' \Sigma_y \alpha - 1) - \mu (\beta' \Sigma_x \beta - 1)$$

$$\left. \begin{aligned} \frac{\partial L}{\partial \alpha} &= 2(\alpha' \Sigma_{yx} \beta) \Sigma_{yx} \beta - 2\lambda \Sigma_y \alpha = 0 \Leftrightarrow (\alpha' \Sigma_{yx} \beta)^2 = \lambda \alpha' \Sigma_y \alpha = \lambda \\ \frac{\partial L}{\partial \beta} &= 2(\alpha' \Sigma_{yx} \beta) \alpha' \Sigma_{yx} - 2\mu \beta' \Sigma_x = 0 \Leftrightarrow (\alpha' \Sigma_{yx} \beta)^2 = \mu \beta' \Sigma_x \beta = \mu \end{aligned} \right\} \Rightarrow \lambda = \mu = (\alpha' \Sigma_{yx} \beta)^2 = \rho^2$$

- de donde

$$\Sigma_{yx} \beta = (\alpha' \Sigma_{yx} \beta) \Sigma_y \alpha \Leftrightarrow \alpha = \frac{\Sigma_y^{-1} \Sigma_{yx} \beta}{(\alpha' \Sigma_{yx} \beta)}$$

$$\alpha' \Sigma_{yx} = (\alpha' \Sigma_{yx} \beta) \beta' \Sigma_x \Leftrightarrow \Sigma_{xy} \alpha = (\alpha' \Sigma_{yx} \beta) \Sigma_x \beta \Leftrightarrow \beta = \frac{\Sigma_x^{-1} \Sigma_{xy} \alpha}{(\alpha' \Sigma_{yx} \beta)}$$

- lo que conduce a

$$\begin{aligned} \beta' \Sigma_{xy} \Sigma_y^{-1} \Sigma_{yx} \Sigma_x^{-1} &= (\alpha' \Sigma_{yx} \beta)^2 \beta' = \rho^2 \beta' \Leftrightarrow (\Sigma_x^{-1} \Sigma_{xy} \Sigma_y^{-1} \Sigma_{yx}) \beta = \rho^2 \beta \\ (\Sigma_y^{-1} \Sigma_{yx} \Sigma_x^{-1} \Sigma_{xy}) \alpha &= (\alpha' \Sigma_{yx} \beta)^2 \alpha = \rho^2 \alpha \end{aligned}$$

## Análisis de Correlación Canónica

### Cálculo de la primera pareja de variables canónicas

- Por lo que:

$\beta$  es un autovector de la matriz  $\Sigma_x^{-1} \Sigma_{xy} \Sigma_y^{-1} \Sigma_{yx}$

$\alpha$  es un autovector de la matriz  $\Sigma_y^{-1} \Sigma_{yx} \Sigma_x^{-1} \Sigma_{xy}$

- esas matrices, de dimensiones  $p \times p$  y  $q \times q$  respectivamente tienen el mismo número ( $\min(p, q)$ ) de autovalores no nulos ( $\rho^2$ ) y coinciden dos a dos
- se define el *primer coeficiente de correlación canónica* como el coeficiente de correlación lineal simple de Fisher,  $\rho$ , entre dichas dos primeras variables canónicas

- Además,

$$\alpha = \frac{\Sigma_y^{-1} \Sigma_{yx} \beta}{(\alpha' \Sigma_{yx} \beta)} = \frac{\Sigma_y^{-1} \Sigma_{yx} \beta}{\rho} \quad \text{y} \quad \beta = \frac{\Sigma_x^{-1} \Sigma_{xy} \alpha}{(\alpha' \Sigma_{xy} \alpha)} = \frac{\Sigma_x^{-1} \Sigma_{xy} \alpha}{\rho}$$

## Análisis de Correlación Canónica

### Cálculo de las sucesivas variables canónicas

- Supongamos que ya disponemos de  $r-1$  parejas de variables canónicas, que ordenamos matricialmente de la siguiente forma:

$$A_{(r-1)} = \begin{pmatrix} \alpha_1^{(1)} & \alpha_1^{(2)} & \dots & \alpha_1^{(r-1)} \\ \alpha_2^{(1)} & \alpha_2^{(2)} & \dots & \alpha_2^{(r-1)} \\ \vdots & \vdots & \ddots & \vdots \\ \alpha_q^{(1)} & \alpha_q^{(2)} & \dots & \alpha_q^{(r-1)} \end{pmatrix}, \quad B_{(r-1)} = \begin{pmatrix} \beta_1^{(1)} & \beta_1^{(2)} & \dots & \beta_1^{(r-1)} \\ \beta_2^{(1)} & \beta_2^{(2)} & \dots & \beta_2^{(r-1)} \\ \vdots & \vdots & \ddots & \vdots \\ \beta_p^{(1)} & \beta_p^{(2)} & \dots & \beta_p^{(r-1)} \end{pmatrix}$$

- Estas variables canónicas cumplirán, por las exigencias anteriores que sus correlaciones internas en cada grupo serán nulas; lo que podemos expresar como:

$$A_{(r-1)}' \Sigma_y A_{(r-1)} = I \quad \text{y que} \quad B_{(r-1)}' \Sigma_x B_{(r-1)} = I$$

- y que las correlaciones cruzadas con las anteriores sean nulas; lo que podemos expresar como

$$A_{(r-1)}' \Sigma_{yx} B_{(r-1)} = \begin{pmatrix} \rho_{(1)} & 0 & \dots & 0 \\ 0 & \rho_{(2)} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \rho_{(r-1)} \end{pmatrix}_{(r-1) \times (r-1)} = P_{(r-1)}$$

## Análisis de Correlación Canónica

### Cálculo de las sucesivas variables canónicas

- el problema de encontrar la  $r$ -ésima pareja de variables canónicas será:

\* Encontrar los vectores columnas  $\alpha^{(r)}$  y  $\beta^{(r)}$  tales que :

$$A_{(r)}' \Sigma_y A_{(r)} = I, \quad B_{(r)}' \Sigma_x B_{(r)} = I, \quad A_{(r)}' \Sigma_{yx} B_{(r)} = P_{(r)}$$

y que hagan máximo el cuadrado de la correlación lineal  $\rho^2$  entre las variables  $X^{(r)}, Y^{(r)}$  siendo :

$$Y^{(r)} = \alpha_1^{(r)} Y_1 + \alpha_2^{(r)} Y_2 + \dots + \alpha_q^{(r)} Y_q \quad \text{y} \quad X^{(r)} = \beta_1^{(r)} X_1 + \beta_2^{(r)} X_2 + \dots + \beta_p^{(r)} X_p$$

o, equivalentemente

$$\text{Maximizar } \rho_{(r)}^2 = (\alpha^{(r)'} \Sigma_{yx} \beta^{(r)})^2 \quad \text{sujeto a las restricciones:} \quad \begin{cases} A_{(r)}' \Sigma_y A_{(r)} = I \\ B_{(r)}' \Sigma_x B_{(r)} = I \\ A_{(r)}' \Sigma_{yx} B_{(r)} = P_{(r)} \end{cases}$$

## Análisis de Correlación Canónica

### Cálculo de las sucesivas variables canónicas

- las nuevas parejas de variables canónicas vuelven a estar caracterizadas por los autovectores de las mismas matrices deducidas para la primera variable canónica,  $\Sigma_x^{-1} \Sigma_{yx} \Sigma_y^{-1} \Sigma_{yx}$  y  $\Sigma_y^{-1} \Sigma_{yx} \Sigma_x^{-1} \Sigma_{yx}$ , presentando siempre el mismo autovalor asociado para cada pareja.
- Así, si son  $\rho_{(1)}^2 \geq \rho_{(2)}^2 \geq \dots \geq \rho_{(\min(p,q))}^2 \geq 0$  los mayores autovalores de ambas matrices, las sucesivas parejas de variables canónicas serán justamente aquellas que toman por coeficientes los autovectores asociados a los autovalores,  $\rho_{(r)}^2$ , de sus correspondientes matrices anteriormente deducidas, ordenadamente de mayor a menor.
- $\rho_{(r)}^2$  será pues el coeficiente de determinación entre las  $r$ -ésimas variables canónicas; por lo que se define el  *$r$ -ésimo coeficiente de correlación canónica* como el coeficiente de correlación lineal simple de Fisher,  $\rho_{(r)}$ , entre dichas  $r$ -ésimas variables canónicas.

## Análisis de Correlación Canónica

### Interpretación geométrica

- En el espacio de los casos, el coseno del ángulo que forma cada pareja de variables canónicas puede calcularse como:

$$\cos(\phi) = \frac{(Y\alpha^{(k)})'(X\beta^{(k)})}{|Y\alpha^{(k)}| |X\beta^{(k)}|} \Leftrightarrow \cos^2(\phi) = \frac{((Y\alpha^{(k)})'(X\beta^{(k)}))^2}{|Y\alpha^{(k)}|^2 |X\beta^{(k)}|^2} = \frac{((Y\alpha^{(k)})'(X\beta^{(k)}))^2}{(Y\alpha^{(k)})(Y\alpha^{(k)})(X\beta^{(k)})(X\beta^{(k)})}$$

de donde

$$\cos^2(\phi) = \frac{\left(\alpha^{(k)'} \frac{1}{n} (Y'X) \beta^{(k)}\right)^2}{\left(\alpha^{(k)'} \frac{1}{n} (Y'Y) \alpha^{(k)}\right) \left(\beta^{(k)'} \frac{1}{n} (X'X) \beta^{(k)}\right)} = \frac{(\alpha^{(k)'} S_{yx} \beta^{(k)})^2}{(\alpha^{(k)'} S_y^2 \alpha^{(k)}) (\beta^{(k)'} S_x^2 \beta^{(k)})} = \hat{\rho}_{(k)}^2$$

## Análisis de Correlación Canónica

### Propiedades

- Las variables canónicas  $(X^{(r)})$  están tipificadas y se encuentran incorrelacionadas entre sí para  $r \neq s$ . Análogamente para las  $(Y^{(r)})$ .
- Las parejas de variables canónicas  $(X^{(r)}, Y^{(s)})$ , presentan una correlación máxima cuando  $r=s=\min(r,s)$ , y una correlación nula cuando  $r \neq s$ .
- El cuadrado del coeficiente de correlación lineal,  $\rho_{(r)}^2$ , que presetan las parejas de variables canónicas  $(X^{(r)}, Y^{(s)})$ , es su autovalor (común) asociado.
- Ese autovalor representa la proporción de varianza de  $X^{(r)}$  explicada por las  $\{Y_1, Y_2, \dots, Y_q\}$ ; así como la proporción de varianza de  $Y^{(r)}$  explicada por las  $\{X_1, X_2, \dots, X_p\}$ .

# Análisis de Correlación Canónica

## Propiedades

- los coeficientes de la  $r$ -ésima pareja de variables canónicas son los autovectores ligados al mismo  $r$ -ésimo autovalor (una vez ordenados de mayor a menor) de las matrices:

$$\begin{aligned} \Sigma_y^{-1} \Sigma_{yx} \Sigma_x^{-1} \Sigma_{xy} & \quad (\text{sus autovector son los } \alpha^{(r)}) \\ \Sigma_x^{-1} \Sigma_{xy} \Sigma_y^{-1} \Sigma_{yx} & \quad (\text{sus autovector son los } \beta^{(r)}) \end{aligned}$$

- La variable opuesta a una variable canónica, también lo es.
- Las correlaciones canónicas son invariantes ante cambios de origen y escala (transformaciones lineales) de las variables originales: Es decir, si

$$\tilde{y} = A'y + a \quad y \quad \tilde{x} = B'x + b$$

entonces, las correlaciones canónicas entre estas nuevas variables son las mismas que entre  $y$  y  $x$ ; y sus vectores canónicos son:

$$\tilde{\alpha}^{(r)} = A^{-1} \alpha^{(r)} \quad y \quad \tilde{\beta}^{(r)} = B^{-1} \beta^{(r)}$$

- Las correlaciones canónicas no varían al sustituir las variables originales por un mismo número de combinaciones l.i. de las mismas.

# Análisis de Correlación Canónica

## Contrastación del modelo

### Enfoque Muestral

- En la Práctica, podremos estimar las variables canónicas a partir de los autovalores y autovectores de las matrices muestrales:

$$S_y^{-1} S_{yx} S_x^{-1} S_{xy} \quad y \quad S_x^{-1} S_{xy} S_y^{-1} S_{yx}$$

siendo sus autovectores estimadores máximoverosímiles de los coeficientes  $\alpha^{(r)}$  y  $\beta^{(r)}$  recíprocamente, y sus autovalores, estimadores máximoverosímiles de los cuadrados de los correspondientes coeficientes de correlación canónica

## Análisis de Correlación Canónica

### Contrastación del modelo

- Adecuación del Modelo 
$$\begin{cases} H_0 : \Sigma_{yx} = 0 & (\text{matriz nula}) \\ H_1 : \Sigma_{yx} \neq 0 \end{cases}$$
- Bajo la hipótesis de Normalidad Multivariante  $N(\mathbf{0}, \Sigma)$  para el conjunto de todas las variables observadas y, por tanto, de los vectores  $y' = \{Y_1, Y_2, \dots, Y_q\} \in N(\mathbf{0}, \Sigma_y)$  y  $x' = \{X_1, X_2, \dots, X_p\} \in N(\mathbf{0}, \Sigma_x)$ , ocurrirá que:

$$\Lambda = \frac{|\Sigma|}{|\Sigma_y| |\Sigma_x|} = |I - \Sigma_x^{-1} \Sigma_{xy} \Sigma_y^{-1} \Sigma_{yx}| = \prod_{r=1}^h (1 - \rho_{(r)}^2) \xrightarrow[\text{Bajo } H_0]{n \rightarrow \infty} \Lambda(p, n-1-q, q)$$

De donde se obtiene, a partir del test de razón de verosimilitudes

$$\lambda = -2 \ln(\lambda^*) = -2 \ln(\Lambda^{n/2}) = -n \ln(\Lambda) = -n \ln \left( \prod_{r=1}^h (1 - \rho_{(r)}^2) \right) = -n \left( \sum_{r=1}^h \ln(1 - \rho_{(r)}^2) \right) \xrightarrow[\text{Bajo } H_0]{n \rightarrow \infty} \chi_{pq}^2$$

- y por la aproximación de Bartlett 
$$-\left(s - \frac{n-t+1}{2}\right) \ln(\Lambda(n, s, t)) \xrightarrow{s \rightarrow \infty} \chi_{nt}^2$$
 que 
$$-\left(n - \frac{3+p+q}{2}\right) \ln(\Lambda) = -\left(n - \frac{3+p+q}{2}\right) \left( \sum_{r=1}^h \ln(1 - \rho_{(r)}^2) \right) \xrightarrow[\text{Bajo } H_0]{n \rightarrow \infty} \chi_{pq}^2$$

## Análisis de Correlación Canónica

### Contrastación del Modelo

- Análisis de la Dimensionalidad 
$$\begin{cases} H_0 : \rho_{(k+1)}^2 = 0 & (\Rightarrow \rho_{(k+2)}^2 = \dots = \rho_{(h)}^2 = 0) \\ H_1 : \rho_{(k+1)}^2 > 0 \end{cases}, k = 0, 1, \dots, h-1$$
- Bajo la hipótesis de Normalidad Multivariante  $N(\mathbf{0}, \Sigma)$  para el conjunto de todas las variables observadas y, por tanto, de los vectores  $y' = \{Y_1, Y_2, \dots, Y_q\} \in N(\mathbf{0}, \Sigma_y)$  y  $x' = \{X_1, X_2, \dots, X_p\} \in N(\mathbf{0}, \Sigma_x)$ , el estadístico experimental del correspondiente contraste de razón de verosimilitudes será:

$$\lambda = -\left(n - \frac{3+p+q}{2}\right) \left( \sum_{r=k+1}^h \ln(1 - \rho_{(r)}^2) \right) \xrightarrow[\text{Bajo } H_0]{n \rightarrow \infty} \chi_{(p-k)(q-k)}^2$$

- Aternativamente, el estadístico experimental de Bartlett-Lawley será:

$$L_k = -\left(n - k - \frac{3+p+q}{2} + \sum_{r=1}^k \rho_{(r)}^{-2}\right) \left( \sum_{r=k+1}^h \ln(1 - \rho_{(r)}^2) \right) \xrightarrow[\text{Bajo } H_0]{n \rightarrow \infty} \chi_{(p-k)(q-k)}^2$$



# Análisis de Correlación Canónica

## Relación con otras técnicas de análisis multivariante

- Regresión simple
  - es el caso  $p=q=1$
  - las submatrices  $\Sigma_y$ ,  $\Sigma_{yx}$ ,  $\Sigma_x$  son respectivamente los escalares varianza de  $Y$ , Covarianza de  $Y$  con  $X$  y varianza de  $X$ ; por lo que el coeficiente de correlación canónica es:

$$\rho^2 = \Sigma_y^{-1} \Sigma_{yx} \Sigma_x^{-1} \Sigma_{xy} = \frac{\sigma_{xy}^2}{\sigma_x^2 \cdot \sigma_y^2}$$

- Regresión múltiple
  - es el caso  $p=p, q=1$
  - las submatrices  $\Sigma_y$ ,  $\Sigma_{yx}$ ,  $\Sigma_x$  son respectivamente el escalar varianza de  $Y$ , el vector de dimensión  $p$  de las covarianzas de la variable  $Y$  con las  $X$ 's y la matriz de dimensión  $p \cdot p$  de varianzas y covarianzas de las  $X$ 's; por lo que el coeficiente de correlación canónica es:

$$\rho^2 = \Sigma_y^{-1} \Sigma_{yx} \Sigma_x^{-1} \Sigma_{xy} = \frac{\Sigma_{yx} \Sigma_x^{-1} \Sigma_{xy}}{\sigma_y^2} = \frac{\sigma_y^2}{\sigma_y^2}$$

# Análisis de Correlación Canónica

## Relación con otras técnicas de análisis multivariante

- Análisis Discriminante
  - Es el caso cuando definimos las  $q$  variables  $Y$ 's como indicadoras de pertenencia a cada uno de los  $q+1$  grupos de la variable categórica grupo del Análisis Discriminante, de la forma usual (*método indicador*)

$$Y_i = \begin{cases} 1 & \text{si el caso pertenece al grupo } i - \text{ésimo, } i = 1, \dots, q \\ 0 & \text{si el caso pertenece a otro grupo distinto} \end{cases}$$

- En este caso, el cuadrado del coeficiente de correlación canónica es:

$$\rho_r^2 = \frac{\lambda_r}{1 + \lambda_r} = \frac{\text{varianza inter - grupos del eje discriminante } r - \text{ésimo}}{\text{varianza total del eje discriminante } r - \text{ésimo}} = \frac{u_r' B u_r}{u_r' S u_r} = \eta_r^2$$

siendo  $\lambda_r$  el autovalor asociado a la función discriminante  $r$ -ésima

# Análisis de Correlación Canónica

## Relación con otras técnicas de análisis multivariante

- Tablas de Contingencia
    - Es el caso en que definimos las  $q$  variables  $Y$ 's como indicadoras de la observación de cada una de las  $q$  modalidades de uno de los atributos de la tabla (por ejemplo, atributo-columna) y las  $p$  variables  $X$ 's como indicadoras de ocurrencia de cada una de las  $p$  modalidades del otro atributo de la tabla (por ejemplo, atributo-fila).
- $$Y_i = \begin{cases} 1 & \text{si el caso presenta el atributo columna } i - \text{ésimo} \\ 0 & \text{si el caso pertenece a otro grupo distinto} \end{cases}$$
- $$X_i = \begin{cases} 1 & \text{si el caso presenta el atributo fila } i - \text{ésimo} \\ 0 & \text{si el caso pertenece a otro grupo distinto} \end{cases}$$
- la asociación entre los atributos (variables cualitativas) puede estudiarse a partir de  $h-1 = \min(p, q) - 1$  relaciones canónicas
  - Si la primera pareja de variables canónicas presente correlación canónica nula, ello indicaría la no asociación o independencia de los dos atributos enfrentados en la tabla.

# Análisis de Correlación Canónica

## Coefficientes de Redundancia

- Se define *Coefficiente de Redundancia* entre la variable  $X^{(k)} = \beta^{(k)'} x = \beta_1^{(k)} X_1 + \beta_2^{(k)} X_2 + \dots + \beta_p^{(k)} X_p$  y el conjunto de variables endógenas  $Y_1, Y_2, \dots, Y_q$ , como el promedio de los cuadrados de las correlaciones entre la variable  $X^{(k)}$  y cada una de las  $Y_1, Y_2, \dots, Y_q$ .

- Supuestas las variables tipificadas, como

$$\text{Corr}(y, X^{(k)}) = \text{Cov}(y, X^{(k)}) = E\left[y\left(\beta^{(k)'} x\right)\right] = E[yx']\beta^{(k)} = \Sigma_{yx}\beta^{(k)} = P_{yx}\beta^{(k)}$$

entonces:

$$CR(y | X^{(k)}) = \frac{1}{q} (\Sigma_{yx}\beta^{(k)})' (\Sigma_{yx}\beta^{(k)}) = \frac{1}{q} \beta^{(k)'} \Sigma_{xy} \Sigma_{yx} \beta^{(k)} = \frac{1}{q} \beta^{(k)'} P_{yx} P_{yx} \beta^{(k)}$$

## Análisis de Correlación Canónica

### Coefficientes de Redundancia

- Se define *Coefficiente de Redundancia Total* como la suma de las redundancias anteriores para el conjunto de las  $h$  combinaciones lineales
- Supuestas las variables tipificadas,

$$CR(y | x) = \sum_{k=1}^h CR(Y | X^{(k)}) = \frac{1}{q} \sum_{k=1}^h \beta^{(k)'} \Sigma_{xy} \Sigma_{yx} \beta^{(k)} = \frac{1}{q} \sum_{k=1}^h \beta^{(k)'} P_{xy} P_{yx} \beta^{(k)}$$

- Cuando se aplican sobre las variables canónicas obtenidas por el procedimiento anteriormente expuesto sobre las variables tipificadas, puede demostrarse que:

$$CR(y | x) = \frac{\text{Traza}(P_{yx} P_{xx}^{-1} P_{xy})}{\text{Traza}(P_{yy})} = \frac{1}{q} \sum_{k=1}^q R_{Y_k, X_1, X_2, \dots, X_p}^2$$

## Análisis de Correlación Canónica

### Análisis Canónico Asimétrico

- Uno de los conjuntos de variables (por ejemplo las  $X$ 's) se consideran variables exógenas o explicativas de las variables del otro grupo (en este caso, las  $Y$ 's) que se consideran variables endógenas o explicadas.
- El Análisis Canónico Asimétrico, desarrollado por Stewart y Love (1968) y Gudmundsson (1977), trata de encontrar combinaciones lineales tipificadas de las variables exógenas

$$X^{(k)} = \beta^{(k)'} x = \beta_1^{(k)} X_1 + \beta_2^{(k)} X_2 + \dots + \beta_p^{(k)} X_p$$

de forma que presenten las más altas correlaciones con las variables del conjunto de variables endógenas  $Y_1, Y_2, \dots, Y_q$  que se pretenden explicar, y utilizando como medida de correlación global el coeficiente de Redundancia Total; que en el caso de variables tipificadas es:

$$CR(y | x) = \sum_{k=1}^h CR(Y | X^{(k)}) = \frac{1}{q} \sum_{k=1}^h \beta^{(k)'} \Sigma_{xy} \Sigma_{yx} \beta^{(k)} = \frac{1}{q} \sum_{k=1}^h \beta^{(k)'} P_{xy} P_{yx} \beta^{(k)}$$

# Análisis de Correlación Canónica

## Análisis Canónico Asimétrico

- Si todas las variables  $X$ 's e  $Y$ 's se encuentran tipificadas, el problema se plantea como:

\* Encontrar  $\beta^{(1)}$  tal que :  $Var(X^{(1)}) = 1$  y  $CR(Y | X^{(1)})$  sea máximo  
o lo que es equivalente,

$$\text{Maximizar } \beta^{(1)'} \Sigma_{xy} \Sigma_{yx} \beta^{(1)} \text{ sujeto a la restricción : } \beta^{(1)'} \Sigma_{xx} \beta^{(1)} = 1$$

lo que conduce a la ecuación:

$$\Sigma_{xy} \Sigma_{yx} \beta^{(1)} = \lambda \Sigma_{xx} \beta^{(1)} \text{ o equivalentemente } \Sigma_{xx}^{-1} \Sigma_{xy} \Sigma_{yx} \beta^{(1)} = \lambda \beta^{(1)}$$

- La solución sería el autovector de la matriz  $H = \Sigma_{xx}^{-1} \Sigma_{xy} \Sigma_{yx}$  asociado a su mayor autovalor  $\lambda$ .
- Imponiendo que las sucesivas variables canónicas (en este enfoque asimétrico) sean ortogonales a las anteriores, las obtendríamos como los autovectores de los sucesivos autovalores de la anterior matriz  $H$ .