

ECTRIA - T9. VARIABLES DEPENDIENTES CUALITATIVAS Y LIMITADAS.  
TIPOS DE MODELOS DE ELECCIÓN DISCRETA.  
MODELO DE PROBABILIDAD LINEAL.  
FORMULACIÓN DE UN MODELO DE PROBABILIDAD.  
MODELOS LOGIT Y PROBIT.  
ERRORES DE ESPECIFICACIÓN.  
EXTENSIÓN DEL MODELO BÁSICO: DATOS AGRUPADOS.  
PROBIT ORDENADO.  
MODELOS TOBIT.

---

## MODELOS de ELECCIÓN DISCRETA:

- Fenómeno discreto vs continuo
- la decisión económica que se estudia es el resultado de la elección entre  $\neq$  alternativas discretas.
- Ejemplos:
  - \* Decisión de jubilación (Sí/No)
  - \* Elección entre las marcas de un mismo producto ( $M_1, M_2, \dots$ )
- Se denominan modelos de elección discreta o modelos de respuesta cualitativa a aquellos modelos econométricos en los que la var. dependiente toma un conjunto discreto y finito de valores:  $0, 1, 2, \dots$

### = Tipos

## TIPOS de MODELOS de ELECCIÓN DISCRETA:

### a) Atendiendo al significado de la var. dependiente:

- Modelos de elección binaria o multinomial:
  - ↳ Los valores de la var. dependiente no tienen significado por sí mismos, reflejan un código de pertenencia.
- Modelos de variable con respuesta ordenada:
  - ↳ la var. dependiente no refleja cualidades sino un orden.
- Modelos con datos de recuento:
  - ↳ Los valores de la var. dep. tienen significado por sí mismos.

### b) Atendiendo al tipo de datos:

- Corte transversal o cross-section
  - ↳ observaciones individuales en un momento concreto.
- Longitudinales
  - ↳ A lo largo de diferentes periodos
- Paneles de datos
  - ↳ Mayor nº de agentes que de periodos de tiempo

c) Atendiendo a los supuestos en la especificación:

- Modelos paramétricos

↳ se especifica la forma funcional de la distrib. de los datos.

- Modelos no paramétricos

↳ No se hacen supuestos sobre la distrib. de los datos

- Modelos semiparamétricos

↳ se especifica la forma funcional de algún momento de la distribución, y el resto se estima de forma no paramétrica.

MODELOS con VARIABLE DEPENDIENTE LIMITADA:

- El rango de variación de la var. dependiente está limitado para una parte de la población que estamos analizando.

- Datos truncados:

\* Determinantes de la rent. en hogares pobres

↳ muestra truncada → sólo hogares de rent. baja.

\* Gasto individual en asistencia médica

↳ variable truncada en 0 → sólo estudio piloto.

- Datos censurados:

Los valores de la var. dependiente se restringen a un determinado rango. ~~las var.~~

Las variables explicativas se observan por todos los valores, pero la v.d. sólo para algunos.

\* Renta:  $[0, 500)$ ,  $[500, 1000)$ ,  $[1000, 2000)$ ,  $[2000, 3000)$ ,  $[3000, \rightarrow)$  → censurada por la derecha.

\* N° entradas demandadas medidas a partir del n° de entradas vendidas → variable censurada

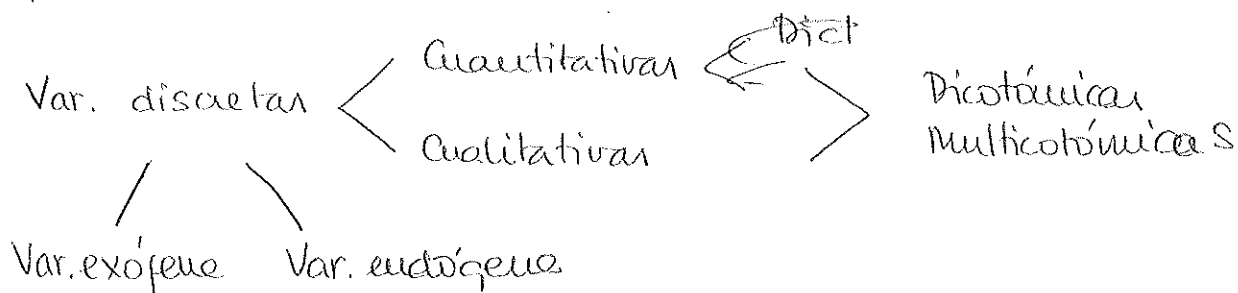
- Problemas de selección muestral:

Existe sesgo de selección muestral cuando una parte de la población (con caract. particulares) no está en la muestra.

1. Modelos de ELECCIÓN DISCRETA

Modelos de regresión lineal en los que alguna de las var. explicativas toma valores en un conjunto finito y discreto.

Por ejemplo, var. artificiales o ficticias que son var. dicotómicas, sólo valen 1 cuando se cumple la característica para la cual han sido introducidas en el modelo.



Modelos de elección binaria,  $Y = \begin{cases} 1 \\ 0 \end{cases}$

$$Y_i = X_i' \beta + u_i, \quad i = 1 \dots N$$

$$Y_i = \begin{cases} 0 \\ 1 \end{cases} \Rightarrow \begin{cases} u_i = 0 - X_i' \beta \\ u_i = 1 - X_i' \beta \end{cases} \left\{ \begin{array}{l} \text{Para que } E[u_i] = 0 \\ \text{Prob} = 1 - X_i' \beta \\ \text{Prob} = X_i' \beta \end{array} \right.$$

1.  $\text{Var}(u_i)$  depende de  $X_i'$   $\Rightarrow$  heteroscedasticidad  $\Rightarrow \hat{\beta}_{\text{MCO}}$  ineficiente
2.  $u_i \not\rightarrow \text{Normal} \Rightarrow$  contrastes clásicos no son válidos  
 $R^2$  no es representativo.
3.  $u_i \not\rightarrow \text{Normal} \Rightarrow$  ~~est~~ ETCO no eficiente  $\Rightarrow$  utilizar est. no lineales
4. los valores de predicción son  $\neq 0$  ó  $1 \Rightarrow$  difícil interpretación
5. la predicción puede interpretarse como la probabilidad de que el individuo  $i$  elija  $Y_i = 1$ .

Modelos de elección limitada,  $Y = \begin{cases} 0 \\ 1 \\ \vdots \end{cases} \leftarrow$  a.º limitado opciones discretas

## 2 - MODELO de PROBABILIDAD LINEAL

$$Y_i = \beta_1 + \beta_2 X_i + u_i$$

donde  $Y_i \equiv$  var. dependiente dicotómica,  $Y_i = \begin{cases} 0 \\ 1 \end{cases}$

$Y_i$  es función lineal de la(s) var. explicat.

Se llama MLP, porque la esperanza condicionada  $E(Y_i/X_i)$  puede ser interpretada como la prob. condicional de que el evento suceda dado  $X_i$ .

$$E(Y_i/X_i) = \Pr(Y_i=1/X_i)$$

Sp. que  $E[u_i] = 0$  (supuesto básico para obtener estim. insesgado)

$$E[u_i] = 0 \Rightarrow E[Y_i/X_i] = \beta_1 + \beta_2 X_i \quad (X_i \text{ determinista})$$

$$P_i = P(Y_i=1) \quad (\text{parám. poblacional}) \quad Y_i \rightarrow B(1, P_i)$$

$$1 - P_i = P(Y_i=0)$$

$Y_i$	Probab
0	$1 - P_i$
1	$P_i$
	1

$$E[Y_i] = 0(1 - P_i) + 1 \cdot P_i = P_i$$

$$E(Y_i/X_i) = E[Y_i] \Leftrightarrow \beta_1 + \beta_2 X_i = P_i$$

$$\Rightarrow 0 \leq E(Y_i/X_i) \leq 1$$

Problemas:

a)  $u_i \rightarrow$  Normal

$$u_i = Y_i - X_i' \beta = Y_i - \beta_1 - \beta_2 X_i$$

$$Y_i = 1 \Rightarrow u_i = 1 - \beta_1 - \beta_2 X_i$$

$$Y_i = 0 \Rightarrow u_i = -\beta_1 - \beta_2 X_i$$

$u_i \rightarrow$  Binomial

↑ debería tomar valores discretos

$\hat{\beta}$  no sigue siendo insesgado

En muestras grandes, con MLP se puede utilizar NCO usual bajo el supuesto de normalidad.

B)  $u_i$  NO autocorrelación, se puede suponer  
 $u_i$  sí heteroscedasticidad.

$u_i$	Probab
$-\beta_1 - \beta_2 X_i$	$1 - P_i$
$1 - \beta_1 - \beta_2 X_i$	$P_i$

$$\begin{aligned} \text{Var}(u_i) &= E(u_i - E(u_i))^2 = E(u_i^2) = \\ &= (-\beta_1 - \beta_2 X_i)^2 (1 - P_i) + (1 - \beta_1 - \beta_2 X_i)^2 P_i \\ &\hookrightarrow \text{reemplazando } P_i \text{ por su valor} \\ &= P_i^2 (1 - P_i) + (1 - P_i)^2 P_i = \\ &= P_i (1 - P_i) (P_i + (1 - P_i)) = \\ &= P_i (1 - P_i) \end{aligned}$$

Recordemos que  $P_i = E(Y_i) = E(Y_i/X_i)$ , por lo que  
 $u_i$  heteroscedástico, porque depende de la esperanza condicional  
 de  $Y$ , depende del valor de  $X$ .

Los estimadores MCO, aunque insesgados, no son eficientes.  
 Se puede transformar el modelo para conseguir un error homosced.  
 Para estimar las ponderaciones: 1.º. Estimar por MCO (ignorando heterosced.)  
 $\hat{w}_i = \hat{y}_i (1 - \hat{y}_i)$   
 2.º. Transformar el modelo con  $\hat{w}_i$   
 y volver a estimar MCO.

B) No cumplimiento de  $0 \leq E(Y_i/X_i) \leq 1$ .  
 No hay garantías de que  $\hat{y}_i$  que son los estimadores de  $E(Y_i/X_i)$   
 cumplan esta restricción  $\rightarrow$  PROBLEMA.

Soluciones:  
 1. Estimar MLP por MCO,  $\hat{y}_i \begin{cases} < 0 \rightarrow \hat{y}_i = 0 \\ > 1 \rightarrow \hat{y}_i = 1 \end{cases}$

2. Diseñar una técnica de estimación que garantice que  
 la probab.  $0 \leq \hat{y}_i \leq 1 \rightarrow$  Modelos Probit y Logit.

4)  $R^2$ , valor medible de la bondad del ajuste.  
 Mejor no utilizarlo.

### 3. FORMULACIÓN de un MODELO de PROBABILIDAD

El principal problema del MLP es que es posible que  $\hat{Y}_i$  se encuentre fuera del rango 0-1.


Podría resolverse utilizando MC restringidos o program. mat.

Aún así, MLP no resulta muy atractivo porque supone que  $P_i = E(Y=1/X_i)$  aumenta linealmente con  $X$ , es decir, el efecto marginal o incremental de  $X$  permanece de todo el tiempo. En la práctica, en los extremos el efecto es más suave.

Por tanto, se necesita un modelo probabilístico que:

- $\hat{Y}_i$  aumenta con  $X_i$ , pero nunca se salga de 0-1
- La relación entre  $X$  e  $Y$  <sup>NO</sup> sea lineal, mejor forma de S.

Se utilizará una función de distrib. acumulativa, FDA, ¿verdad?



Curva logística → Logit  
Curva normal → Probit

## 4. Modelos LOGIT y PROBIT

### a) Modelo LOGIT

$Y_i = \beta_1 + \beta_2 X_i + u_i$ , donde  $Y_i \equiv$  var. dep. dicotómica

$$Z_i = E[Y_i | X_i] = \beta_1 + \beta_2 X_i \rightarrow \text{modelo lineal}$$

Ahora se utiliza la f. distrib. logística acumulativa

$$P_i = \frac{1}{1 + e^{-(\beta_1 + \beta_2 X_i)}} = \frac{1}{1 + e^{-Z_i}} \quad \text{donde } Z_i = \beta_1 + \beta_2 X_i$$

- $-\infty < Z_i < +\infty \Rightarrow 0 < P_i < 1$
- $P_i$  no está linealmente relacionado con  $Z_i$  ( $\Rightarrow$  tampoco con  $X_i$ )
- $P_i$  es no lineal  $\left\{ \begin{array}{l} \text{en } X \\ \text{en } \beta \end{array} \right\} \Rightarrow$  no se puede utilizar MCO

Sin embargo,

$$L_i = \ln \left( \frac{P_i}{1 - P_i} \right) = Z_i = \beta_1 + \beta_2 X_i$$

$$L_i \equiv \text{logit}$$

El logaritmo de las razón de las probab. es lineal en  $X$  y en  $\beta$ .

Características:

- C1.  $P$  va de 0 a 1, pero  $L$  va de  $-\infty$  a  $+\infty$ .
- C2.  $L$  es lineal, las probab. no lo son (contraria con MLP)
- C3.  $\beta_2$  mide el cambio en  $L$  ocasionado por un cambio unit. en  $X$
- C4. Mientras que MLP impone que  $P_i$  está linealmente relacionado con  $X_i$ , el modelo de LOGIT impone que el log. de la razón de probab. está relacionado linealmente con  $X_i$ .

Estimación:

$$L_i = \ln \left( \frac{P_i}{1 - P_i} \right) = \beta_1 + \beta_2 X_i + u_i$$

Cuando  $P=1$  ó  $P=0$ ,  $L_i$  no tiene sentido.

- Con información individual, no se puede estimar por MCO. Hay que estimar por MV.



• Para información con valores repetidos, se pueden utilizar las frecuencias relativas como estimaciones de  $P_i$  de cada  $X_i$ , y a partir de ahí el logit estimado.

$$\hat{P}_i = \frac{n_i}{N_i} \rightarrow \hat{L}_i = \ln \left( \frac{\hat{P}_i}{1 - \hat{P}_i} \right) = \hat{\beta}_1 + \hat{\beta}_2 X_i$$

Si  $N_i$  es sufic. grande,  $\hat{P}_i$  es buen estimador.

Si además, ~~XXXX~~ ~~se distribuye de manera indep.~~

$Y_i$  se distribuye de manera indep. como  $B(1, P_i)$   
entonces  $u_i \rightarrow N \left( 0, \frac{1}{\sqrt{N_i P_i (1 - P_i)}} \right)$

•  $u_i$  es heteroscedástico  $\Rightarrow$  utilizar MCG en vez de MCO, (es lo mismo que MCO como transformado)

Procedimiento:

1 - Para cada grupo de  $X_i$ , calcular  $\hat{P}_i = \frac{n_i}{N_i}$ .

2 - Para cada  $X_i$ , calcular  $\hat{L}_i = \ln \left( \frac{\hat{P}_i}{1 - \hat{P}_i} \right)$

3 - Para resolver la heteroscedasticidad, logit transformado:

$$L_i^* = \beta_1 \sqrt{w_i} + \beta_2 X_i^* + u_i$$

4 - Estímese el modelo transformado por MCO.

5 - Realizar estimaciones / inferencias (sólo válido para  $N$  grande)

b) Modelo Probit

Utiliza como función de distribución acumulada (FDA) la de una Normal.

$$Y_i = \beta_1 + \beta_2 X_i + u_i, \text{ donde } Y_i = \begin{cases} 1 \\ 0 \end{cases}$$

$$P_i = P(Y=1) =$$

Sp. que existe un indicador dependiente de  $X$  que determina la decisión tomada por cada individuo

$$Y_i = 1 \text{ si } I_i > I_i^* \text{ (valor crítico)} \rightarrow I_i^* < I_i = X_i' \beta$$

$$Y_i = 0 \text{ si } I_i < I_i^* \quad I_i = \beta_1 + \beta_2 X_i$$


Por ser desconocido, consideramos  $I_i^*$  como una var. aleatoria. Utilizando la Normal,

$$P_i = E(Y_i/X_i) = P(Y_i=1/X_i) = P(I_i^* < I_i) =$$

$$= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{X_i' \beta} e^{-t^2/2} dt$$

, que es una f. asociada del indicador  $I_i = X_i' \beta$ .

donde  $t \rightarrow N(0,1)$ .



En la práctica,  $\hat{P}_i = \frac{n_i}{N_i}$   
 $\hat{P}_i \rightarrow \hat{I}_i$  (tabla normal)

Se puede proceder de manera análoga al logit.

Tb. el término de error será heteroscedástico  $\Rightarrow$  transformar el modelo

Comparación logit y probit

- Curva normal se acerca más rápido a los ejes que la curva logíst.
- Operacionalmente, logit es + fácil, se utiliza +.
- Aunque los resultados son similares, los estímac. no son comp.
- (Estimación logit) \* 0.625  $\approx$  Estim. probit
- $\hat{\beta}_{NLP} \approx 0.25 \hat{\beta}_{logit}$  (excepto  $\hat{\beta}_1$ , sumo 0.5).

MODELO TOBIT

Es una extensión del modelo Probit.

Interesa un modelo sobre una nueva variable en función de las var. explicativas que teníamos antes.

Sólo nos interesa el valor  $Y_i = 1$

$$N = \begin{cases} n_1 \rightarrow Y_i = 1 & \rightarrow \text{disponemos inform. de var. endógena} \\ n_2 \rightarrow Y_i = 0 & \rightarrow \text{sobre la var. endógena} \end{cases}$$

Cuando en una muestra la información sólo está disponible para algunas observaciones, ésta se conoce como muestra censurada  $\Rightarrow$  Tobit, modelo de regresión censurada, o de var. dependiente limitada, debido a la restricción impuesta sobre los valores de la var. endógena.

$$Z_i = \beta_1 + \beta_2 X_{2i} + u_{2i} \quad \text{si } RHS > 0 \\ = 0 \quad \text{en los demás casos.}$$

NCO serán sesgadas y serán inconsistentes  
Hay que utilizar MV.

## MODELOS DE ELECCION DISCRETA

Alguna var. explicativa toma valores discretos.

### MODELOS DE ELECCION BINARIA

$$Y_i = X_i' \beta + u_i, \quad i = 1 \dots N \quad Y_i = \begin{cases} 0 \\ 1 \end{cases} \Rightarrow u_i = \begin{cases} -X_i' \beta \\ 1 - X_i' \beta \end{cases} \quad \text{para } E(u) = 0$$

$P(Y_i = 0) = P = 1 - X_i' \beta$

- $E(u_i) = 0$
- $V(u_i) = (1 - X_i' \beta) \cdot X_i' \beta$  depende de  $X \Rightarrow$  heteroscedasticidad  
 $\Rightarrow \hat{\beta}$  no eficiente
- $u_i \not\rightarrow$  Normal  $\Rightarrow$  Contraste de normalidad  
 $R^2$  no representativo  
ENCO no eficiente  $\Rightarrow$  estim. no lineales
- Predicciones  $\neq \{0, 1\} \Rightarrow$  interpretar como una probab.

### Modelo Probab. Lineal, MLP

$$Y_i = \beta_1 + \beta_2 X_i + u_i, \quad Y_i \rightarrow B(1, P_i)$$


$$E(u_i) = 0 \Leftrightarrow P_i = \beta_1 + \beta_2 X_i$$

$V(u_i)$  depende de  $X \Rightarrow$  heteroscedastic  $\Rightarrow \hat{\beta}$  no eficiente

$u_i \not\rightarrow$  Normal  $\Rightarrow \hat{\beta}$  no insesgado, no normal, asintót.

$$E(Y_i) = P_i = E[Y_i/X_i] \Rightarrow 0 \leq E[Y_i/X_i] \leq 1 \quad \leftarrow \text{no siempre.}$$

$R^2 \rightarrow$  mejor no utilizarlo



### PROBIT y LOGIT

Substituto de MLP utilizando curvas crecientes, entre 0 y 1 no lineales, con forma de S.

Probit  $\rightarrow$  utiliz. FDA de Normal para  $P_i$

Logit  $\rightarrow$  utiliz. Curva logística para  $P_i$  (+ sencillo)

Tobit  $\rightarrow$  extensión del Probit para datos censurados

# MODELOS de elección BINARIA (elección limitada, $Y = \begin{cases} 0 \\ 1 \end{cases}$ )

1. Introducción  $X_i' \beta = \beta_1 + \beta_2 X_i$ , en los siguientes casos.

$$Y_i = X_i' \beta + u_i, \quad i = 1 \dots N \quad (\text{datos sección cruzada})$$

$$Y_i = \begin{cases} 0 \\ 1 \end{cases} \Rightarrow u_i = Y_i - X_i' \beta \Rightarrow u_i = -X_i' \beta$$

$$\Rightarrow \text{también} \Rightarrow u_i = 1 - X_i' \beta$$

• Esperanza

$$E[u_i] = \sum u_i P(u_i) = -X_i' \beta \cdot P(u_0) + (1 - X_i' \beta) P(u_1)$$

$$\text{donde } P(u_1) = 1 - P(u_0)$$

$$E[u_i] = 0 \Leftrightarrow -X_i' \beta \cdot P(u_0) + (1 - X_i' \beta) \cdot (1 - P(u_0)) = 0$$

$$\downarrow$$

para que la esperanza sea insesgada!

$$\Leftrightarrow P = 1 - X_i' \beta$$

• Varianza

$$V[u_i] = E[(u_i - E(u_i))^2] = E[(u_i)^2] = (-X_i' \beta)^2 (1 - X_i' \beta) +$$

$$P_i(1 - P_i) + (1 - X_i' \beta)^2 X_i' \beta =$$

$$= (1 - X_i' \beta) [(-X_i' \beta)^2 + (1 - X_i' \beta) X_i' \beta] =$$

$$= (1 - X_i' \beta) [(-X_i' \beta)^2 + X_i' \beta - (X_i' \beta)^2] =$$

$$= (1 - X_i' \beta) \cdot X_i' \beta \Rightarrow \text{depende de } X \Rightarrow \text{heterosced.}$$

Resumiendo:

	$u_i$	$P(u_i) = P(Y_i)$	INSESADO $E(u_i)$	$V(u_i)$
$Y_i = 0 \Rightarrow$	$-X_i' \beta$	$1 - X_i' \beta$	0	$(1 - X_i' \beta) \cdot X_i' \beta$
$Y_i = 1 \Rightarrow$	$1 - X_i' \beta$	$X_i' \beta = P_i$		$P_i(1 - P_i)$

$u_i \not\sim \text{NORMAL}$   
Binomial


$\Rightarrow$  Contrastes no válidos,  $R^2$  no es representativo  
• Estimaciones MCO no eficientes (HETEROSCED)

Predicciones

$\rightarrow$  • Pueden ser  $\neq 0$  o  $\neq 1 \Rightarrow$  difícil interpretación  
• Interpretarle como una probab.

(Probab. lineal pq.  $\hat{Y}_i = E(Y_i/X_i) = \hat{P}_i \equiv \text{probab. de que } Y_i=1$ ) Resumi-2

## 2. Modelo de Probabilidad Lineal (MLP)



$$Y_i = \beta_1 + \beta_2 X_i + u_i$$

$$E(Y_i/X_i) = P(Y_i=1/X_i) = P_i \leftarrow \text{MLP.}$$

$$E(u_i) = 0$$

Para cada valor de  $X_i$ ,

$$\begin{aligned} Y_i = 0 &\Rightarrow u_i = -\beta_1 - \beta_2 X_i \\ Y_i = 1 &\Rightarrow u_i = 1 - \beta_1 - \beta_2 X_i \end{aligned} \quad \left\{ \begin{aligned} E(u_i) &= (-\beta_1 - \beta_2 X_i) \cdot P(Y_i=0) + \\ &\quad + (1 - \beta_1 - \beta_2 X_i) P(Y_i=1) \end{aligned} \right.$$

$$\begin{aligned} \text{Llamando } P(Y_i=1) &= P_i & Y_i &\rightarrow B(1, P_i) & E(Y_i) &= P_i \\ P(Y_i=0) &= 1 - P_i & & & V(Y_i) &= P_i(1 - P_i) \end{aligned}$$

$$\begin{aligned} E(u_i) &= (-\beta_1 - \beta_2 X_i)(1 - P_i) + (1 - \beta_1 - \beta_2 X_i) \cdot P_i = \\ &= -\beta_1 - \beta_2 X_i + [\beta_1 + \beta_2 X_i + 1 - \beta_1 - \beta_2 X_i] P_i = \\ &= -\beta_1 - \beta_2 X_i + P_i \end{aligned}$$

$$E(u_i) = 0 \Leftrightarrow P_i = \beta_1 + \beta_2 X_i \quad (\text{para que sea insesgado})$$

$$E(Y_i) = 0 \cdot P(Y_i=0) + 1 \cdot P(Y_i=1) = P_i$$

$$E(Y_i/X_i) = E(Y_i) \Leftrightarrow P_i = \beta_1 + \beta_2 X_i \Rightarrow 0 \leq E(Y_i/X_i) \leq 1.$$

Resumiendo:

$Y_i$	$P(Y_i)$	$E(u_i)$	$u_i$	$E(u_i)$	$E(Y_i/X_i) = E(Y_i)$	$V(u_i)$
0	$1 - P_i = 1 - \beta_1 - \beta_2 X_i$	$\downarrow$	$-\beta_1 - \beta_2 X_i$	0	$P_i$	$P_i(1 - P_i)$
1	$P_i = \beta_1 + \beta_2 X_i$	$\uparrow$	$1 - \beta_1 - \beta_2 X_i$			

Problemas:

- $u_i \not\rightarrow$  Normal, es binomial  $\Rightarrow \hat{\beta}$  poco insesgado, pero no normal. Para muestras grandes,  $\hat{\beta}$  poco var.

- $V(u_i) = P_i(1 - P_i)$ , depende de  $X \Rightarrow$  heteroscedasticidad

$\hat{\beta}$  poco no eficiente

Transformar el modelo ponderando ( $\hat{W}_i = \hat{Y}_i(1 - \hat{Y}_i) \rightarrow$  Estimación)

- $0 \neq E(Y_i/X_i) \neq 1 \Rightarrow$  Estimar MLP por MCO y si  $\hat{Y}_i < 0 \Rightarrow \hat{Y}_i = 0$   
si  $\hat{Y}_i > 1 \Rightarrow \hat{Y}_i = 1$

$\Rightarrow$  Utilizar Probit y logit.

- $R^2$  no es una buena medida de la bondad del ajuste,

$\Rightarrow$  no utilizarlo

### 3. FORMULACIÓN de un MODELO de PROBAB.


MLP genera predicciones que pueden estar fuera de  $[0,1]$ .

- Utilitar MC restringidos
- Utilitar program. matemática

Aún así, con MLP  $E(Y_i/x_i)$  aumenta de manera lineal con  $X$  (efecto marginal de) → no es muy real

Buscamos un modelo de probab. que:

- No salga de  $[0,1]$
- ~~Aumente~~ Sea suave en los extremos



### 4. Modelos LOGIT y PROBIT.

#### a) LOGIT

$$P(Y_i=1) = P_i = \frac{1}{1 + e^{-(\beta_1 + \beta_2 X_i)}}$$

no es lineal

$$\frac{1}{1 + e^{-Z_i}} \quad / \quad Z_i = \beta_1 + \beta_2 X_i$$

entre 0 y 1

- $-\infty < Z_i < +\infty \Rightarrow 0 \leq P_i \leq 1$
- $P_i$  NO es lineal (ni en  $X$  ni en  $\beta$ )  $\Rightarrow$  no se puede utilizar MCO.
- Pero  $L_i = \ln\left(\frac{P_i}{1-P_i}\right) = Z_i = \beta_1 + \beta_2 X_i$  sí es lineal (en  $X$  y en  $\beta$ ).

$L_i \equiv \text{logit}$ .  ~~$-\infty < L_i < +\infty$ , pero  $0 \leq P_i \leq 1$  pero  $0 \leq P_i \leq 1$~~   
 $\hat{P}_i = \frac{n_i}{N_i}$   
 ¡OJO! Con información individual, no se puede MCO, utilizar MV.


#### b) PROBIT

utiliza como FDA la de una normal.  $I_i = \beta_1 + \beta_2 X_i$

$$P_i = P(Y_i=1/x_i) = P(\text{Normal}(0,1) < I_i) = \int_{-\infty}^{\beta_1 + \beta_2 X_i} \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{1}{2}t^2} dt$$

En la práctica,  $\hat{P}_i = \frac{n_i}{N_i} \rightarrow \hat{I}_i$

Heterosced  $\Rightarrow$  transformer



### COMPARACIÓN:

- Curva logística + suave
- Logit + sencillo  $\Rightarrow$  se utiliz. +
- Estimaciones no comparables
- $\hat{P}_i(\text{logit}) \approx 0.625 \approx \hat{P}_i(\text{probit})$
- $\hat{\beta}_{MLP} \approx 0.25 \hat{\beta}_{\text{LOGIT}}$  (excepto  $\hat{\beta}_1$ , suma 0's)

## 5 - MODELO TOBIT

Extensión del PROBIT.

Cuando en una muestra, sólo tenemos información para algunas observaciones  $\rightarrow$  Muestra censurada

Tobit es modelo de regr. censurada, o de var. dependiente limitada, debido a la restric. impuesta sobre la var. endógena.

$$Z_i = \begin{cases} \beta_1 + \beta_2 X_{2i} + u_{2i} & \text{si RHS} > 0 \text{ (restric.)} \\ 0 & \text{en otro caso.} \end{cases}$$

$\hat{\beta}$  no será sesgado e inconsistente.

Hay que utilizar MV.