

→ homopéneo de orden d .

1. ARIMA (p, d, q)

$I \equiv$ Integrado \equiv se puede transformar en estacionario

Y_t en ARIMA (p, d, q) $\Rightarrow \Delta^d Y_t$ es ARMA (p, q), $\Delta \equiv$ operador diferencia

$$W_t = \Delta^d Y_t = (1-L)^d Y_t$$

$$(1 - \phi_1 L - \dots - \phi_p L^p) W_t = (1 - \theta_1 L - \dots - \theta_q L^q) \varepsilon_t \sim \phi(L) (1-L)^d Y_t = \theta(L) \varepsilon_t$$

Transformación Box y Cox, $Y_t^{(\lambda)} = \begin{cases} \frac{Y_t^\lambda - 1}{\lambda} & \text{si } \lambda \neq 0 \\ \ln Y_t & \text{si } \lambda = 0 \end{cases} \rightarrow \Delta \ln Y_t \equiv \text{tasa variación natural}$

2. METODOLOGÍA de elaboración

Datos \rightarrow Modelo generador

Se parte de una serie temporal conocida (valores observados) y se pretende determinar el modelo ARIMA que más probablemente la haya podido generar.

$$\{Y_1, \dots, Y_T\} \xrightarrow{\text{inferencia}} \phi_p^p(L) \cdot (1-L)^d (Y_t^{(\lambda)} - \mu) = \theta_q^q(L) \cdot \varepsilon_t / \varepsilon_t \rightarrow N(0, \sigma_\varepsilon^2 I_T)$$

Fases: F1 - Identificación (especificación del modelo)

F2 - Estimación (estimación de los parámetros)

F3 - Validación (contrastación de la adecuación del modelo a los datos)

F4 - Predicción (pronóstico de valores futuros)

3. F1 - IDENTIFICACIÓN \rightarrow Especificación del modelo (d, λ , μ)

1º Análisis de la estacionariedad

• No estac. en nivel \rightarrow Tomar diferencias de 1º orden

- Gráfico original no estable en nivel

- Análisis FACE, $\rho \neq 0$ (ir tomando dif. de 1 en 1 y observar FACE)

- Contrastes de raíces unitarias

• No estac. en pendiente \rightarrow Transf. Box y Cox

- Gráfico orig \rightarrow Fluctuaciones que se amplían \rightarrow tomar en (homocedast.)

- Gráfico rango-media: - Renta alineada con tendencia asc. \rightarrow tomar en
- Sin efecto ó horizontal \rightarrow no hacer transf.

• Identificación término indep: $\rightarrow \mu$ ó δ .

- Gráfico s. original \rightarrow mirar nivel (μ)

- Esperar a la fase de estimación \rightarrow de δ

$$Y_t \rightarrow W_t = \underbrace{(1-L)^d}_{3^\circ} \underbrace{\left(\underbrace{Y_t^{(\lambda)}}_{1^\circ} - \underbrace{\mu}_{2^\circ} \right)}_{2^\circ} \rightarrow \text{ARMA}(p, q)$$

2º Identificación de la parte estacionaria \rightarrow Especificación de p y q.

- observando la FAC simple (fas) teorica (T) ó estimada (E)

$$\rho_k = \text{CORR}(Y_t, Y_{t-k}), \hat{\rho}_k = r_k \rightarrow \text{correlac. muestral de } W_t$$

- observando la FACP (función de autocorrelación parcial) K_E^T (fap)

$$\phi_{11} \dots \phi_{kk} (\hat{\phi}_{11} \dots \hat{\phi}_{kk}) = \text{CORR}(Y_t, Y_{t-k}) \text{ sin efecto de } Y_{t-1} \dots Y_{t-(k-1)}$$

AR(p) \rightarrow $\begin{cases} \text{fas} \rightarrow \text{Decrec. rápido geométrico y/o sinusoidal. Infinitos valores.} \\ \text{fap} \rightarrow \hat{\phi}_{kk} = 0, \forall k > p. \end{cases}$

MA(q) \rightarrow $\begin{cases} \text{fas} \rightarrow \hat{\rho}_k = 0, \forall k > q. \\ \text{fap} \rightarrow \text{Decrec. rápido exponencial y/o sinusoidal. Infinitos valores.} \end{cases}$

¿Izblita?

ARMA(p,q) \rightarrow $\begin{cases} \text{fas} \rightarrow 1^{\text{er}} \text{ valores sin patrón fijo + mezcla de oscilac. sinusoidales y/o exponenciales amortiguadas} \\ \text{A partir de } k > q \text{ (orden MA) se comporta como AR} \\ \text{fap} \rightarrow 1^{\text{er}} \text{ valores sin patrón fijo + mezcla de oscilac. sinusoidales y/o exponenciales amortiguadas} \\ \text{Hecha comportamiento MA.} \end{cases}$

En la práctica, se prueba con modelos sencillos, AR(1 ó 2) y se observa el gráfico de residuos, por si tiene estructura MA.

F2. ESTIMACIÓN \rightarrow Estimación de $\phi_i, \theta_i; \sigma_e^2, \mu_w$ o Ordenador.

$y_t \rightarrow w_t = (1-L)^d y_t^{(1)}$, donde $w_t - \phi_1 w_{t-1} - \dots - \phi_p w_{t-p} = \varepsilon_t - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q} + \delta w_t$
o bien $(w_t - \mu_w) - \phi_1 (w_{t-1} - \mu_w) - \dots - \phi_p (w_{t-p} - \mu_w) = \varepsilon_t - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q}$
con $\mu_w = \delta w / (1 - \phi_1 - \dots - \phi_p)$.

Hay que estimar $\phi_1 \dots \phi_p, \theta_1 \dots \theta_q, \mu_w$ y σ_e^2 bajo los supuestos:
+ $\varepsilon_t \rightarrow N(0, \sigma_e^2, I)$ + w_t estacionario e invertible + $\delta w = 0 \Rightarrow \mu_w = 0$.

Estimación por MCO o por MV, solventando los problemas de:
- Valores iniciales $\begin{cases} \text{Enfoque condicional (con } w_1 \dots w_N, w_0 \dots w_{-p+1}, \varepsilon_0 \dots \varepsilon_{-q+1}) \\ \text{Enfoque no condicional (sólo } w_1 \dots w_N, \text{ resto se estima).} \end{cases}$

- Modelo no lineal en los coef ($q \geq 1$) \rightarrow mt. iterativos.

F3. VALIDACIÓN Si $\hat{\varepsilon}_t \sim$ Ruido blanco, OK. Caso contrario \rightarrow a F1.

Un modelo adecuado debería cumplir:

a) Residuos ruido blanco \rightarrow gráfico media 0, sin patrón comport. $\hat{\rho}, \hat{\phi} \sim 0$
independientes, FAP y FACP

b) Modelo estimado estacionario e invertible

Factorizando parte AR, si hay raíces ≈ 1 tomar diferencia 1ª orden.

Factorizando parte MA, si hay raíces ≈ 1 sobredif?

c) Coef. signif $\neq 0$ y poco correlacionados entre sí.

Junto a cada estimac, desv. típica, estadístico ($H_0: \text{coef} = 0$, intersección y el NSC de cada coef.

Revisar matriz de correlaciones por si hay multicolinealidad

d) Coef. del modelo suficiente par explicar la serie bien (R^2 alto)
Probar a introducir mas parámetros y comparar R^2 y \bar{R}^2

e) Modelo estable para periodo futuro

Cuando aparecen nuevas observaciones se comprueba.

6- **F4. PREDICCIÓN** $\hat{y}_{t+k}^T \equiv$ predicción de y_{t+k} con info. hasta T .
 la mejor predicción es la que minimiza el error esperado al cuadrado
 coincide con la esperanza condicional de y_{t+k}

$$\hat{y}_{t+k}^T = E[y_{t+k} / \Omega_T]$$

$$\text{AR}(1) \rightarrow y_t = \delta + \phi y_{t-1} + \varepsilon_t \quad \begin{cases} \hat{y}_{T+1}^T = \delta + \phi y_T & / \hat{\varepsilon}_{T+1} = 0 \text{ (r.b.)} \\ \hat{y}_{T+k}^T = \phi^k y_T + \delta(1 + \phi + \dots + \phi^{k-1}) \\ \hat{y}_{T+k}^T \xrightarrow{k \rightarrow \infty} E[y] \end{cases}$$

$\hookrightarrow \hat{\text{AR}}(p) \rightarrow p$ valores

$$\text{MA}(1) \rightarrow y_t = \varepsilon_t - \theta \varepsilon_{t-1} \xrightarrow{\text{IWR}} y_t = -\theta y_{t-1} - \theta^2 y_{t-2} - \dots + \varepsilon_t$$

$$\hat{y}_{T+1}^T = -\theta y_T - \theta^2 y_{T-1} - \dots + 0$$

$$\hat{y}_{T+k}^T = 0, \forall k > 1$$

\hookrightarrow Para $\text{MA}(q)$, $\hat{y}_{T+k} = 0, k > q$.

$$\text{ARMA}(1,1) \rightarrow y_t = \delta + \phi y_{t-1} + \varepsilon_t - \theta \varepsilon_{t-1} \quad \begin{cases} \hat{y}_{T+1}^T = \delta + \phi y_T + 0 - \theta \hat{\varepsilon}_T \\ \hat{y}_{T+k}^T = (1 + \phi + \dots + \phi^{k-1}) \delta + \phi^k y_T - \theta \phi^{k-1} \hat{\varepsilon}_T \end{cases}$$

$\text{ARIMA} \rightarrow d \neq 0 \rightarrow$ tomar dif. al veca y estimar word. etc. $-\phi \cdot \theta \varepsilon$
 Diferencia cambio en predicción.

$$\Delta z_t = \ln y_t \Rightarrow \hat{y}_{T+k}^T = \exp \left\{ \hat{z}_{T+k}^T + \frac{1}{2} \text{Var}_{\text{error}} \left(\frac{1}{2} \right) \right\}$$

ARIMA (p, d, q)

Metodología de elaboración de un modelo ARIMA

Datos \longrightarrow Modelo generador

$$Y_1 \dots Y_T \quad \rightsquigarrow \quad \phi_p(L)(1-L)^d (Y_t^{(d)} - \mu) = \theta_q(L) \varepsilon_t$$

donde $\varepsilon \sim N(0, \sigma_{\varepsilon}^2 I_T)$

Fase 1. IDENTIFICACIÓN \longrightarrow Especificación del modelo.

1.º. Análisis de la estacionariedad, ¿estacionaria? $\begin{cases} \text{SI} \longrightarrow \text{seguir} \\ \text{NO} \longrightarrow \text{transf.} \end{cases}$

- No estac. en nivel $\textcircled{d} \longrightarrow$ Tomar diferencias de 1.º orden
- No estac. en pendiente $\textcircled{\lambda} \longrightarrow$ Transformación Box y Cox
- Identificación del t. indep? \longrightarrow Incluir $\textcircled{\mu}$ en el modelo.

2.º. Determinación de los órdenes del proceso ARMA.

- Parte autorregresiva $\textcircled{p} \longrightarrow$ Identificar AR(p)
 - Parte media móvil $\textcircled{q} \longrightarrow$ Identificar MA(q)
- > combinados!

(Para identificación)

de Novales

No estacionariedad

Gráfico ~~serie~~ serie original tiene tendencia lineal o cuadrática
 \Rightarrow no estacionario.

Procesos integrados, o procesos estocásticos no estacionarios
homógenos de orden d :

Y_t no es estacionario, pero $\Delta^d Y_t = (1-L)^d Y_t$ si es estac.

Y_t es ARIMA (p, d, q) si $\Delta^d Y_t$ es ARMA (p, q)

Gráfico de la serie temporal muestra fluctuaciones cuya amplitud
cambia para \neq ^{intervalo} periodos de tiempo \Rightarrow no estacionario
(la variación no permanece de a lo largo del tiempo \Rightarrow heterosced)

Transformar logaritmos, caso particular de la transf. Box-Cox

$$Y_t^\lambda = \begin{cases} \frac{Y_t^\lambda - 1}{\lambda} & \text{si } \lambda \neq 0 \\ \ln Y_t & \text{si } \lambda = 0 \end{cases}$$

La transformación logarítmica no va a corregir el problema de
la heteroscedasticidad, lo va a amortiguar, pues que estabi-
liza la variación de la variable.

Para determinar d :

- Análisis gráfico original (no posible en nivel)
- Análisis FASE ($\rho \not\rightarrow 0$)
- Contraste de raíces unit. (Dickey-Fuller)

Para determinar λ :

- Análisis gráfico original (fluctuaciones)
- Gráfico rango-media $\left\{ \begin{array}{l} \text{Puntos, líneas dec} \Rightarrow \text{no estac.} \\ \text{Sin patrón o ox} \Rightarrow \text{estac} \end{array} \right.$

Para determinar μ :

- Gráfico serie original
- Esperar a fue de estim. aver si se usa de.

Identificación de la parte estacionaria

Distinguimos entre función autocorrelación simple (teórica o estimada) y ~~función~~ $\rho_k = \text{CORR}(Y_t, Y_{t-k})$

y función autocorrelación parcial (teórica o estimada), que muestra la correlación entre dos variables ajustada por el efecto de las ^{relaciones} variables intermedias.

$$\phi_{11}, \phi_{22}, \dots, \phi_{kk} = \text{corr}(Y_t, Y_{t-k}) \text{ sin efecto de } Y_{t-1}, \dots, Y_{t(k-1)}$$

⊗

AR(p) → (fas): Decaimiento rápido de tipo geométrico puro o geométrico con atenuancias de sígnos, sinusoidal o mezcla de varios tipos (raíces reales o complejas), infinitos valores.

(fap): Se anula para retardos superiores a p.

MA(q) → (fas): Se anula para retardos superiores a q.

(fap): Decaimiento rápido de tipo exponencial y/o sinusoidal.

ARMA(p, q) → (fas): Primeros valores iniciales sin patrón fijo, seguido de mezcla de oscilaciones sinusoidales y/o exponenciales amortiguadas.

(fap): Primeros valores sin patrón fijo, mezcla de oscilaciones sinusoidales y/o exponenciales amortiguadas.

↓ A partir de $k > q$ (orden MA) se comporta como un AR(p)

↓ luego el comportamiento MA.

En la práctica, se prueba con distintas especificaciones

Por ejemplo, partir de un AR, y observar si los residuos tienen estructura MA (o recíprocamente)

Predicción con modelos ARIMA

Cuando se pretende predecir \hat{y}_{t+k}^T con la información hasta T , la mejor predicción, la que minimiza el error esperado al cuadrado, es la esperanza condicional de la var. y_{T+k}

$$\hat{y}_{T+k}^T = E(y_{T+k} / \Omega_T)$$

$$\text{AR}(1) \rightarrow y_t = \delta + \phi y_{t-1} + \varepsilon_t$$

$$\text{AR}(1) \rightarrow E(y_{T+1} / \Omega_T) = E(\delta + \phi y_T + \varepsilon_{T+1}) = \delta + \phi y_T$$

porque y_T conocido en T

$$E[\varepsilon_{T+1} / \Omega_T] = 0, \text{ por ser ruido blanco}$$

$$E(\bar{y}_{T+k} / \bar{\Omega}_T) = \phi^k y_T + \underbrace{\delta(1 + \phi + \dots + \phi^{k-1})}_{\text{función de } E(y)}$$

$$k \rightarrow +\infty \Rightarrow \hat{y}_{T+k} = E(y)$$

En un $\text{AR}(p)$ se necesitan las p últimas observaciones de y para hacer una predicción.

$$\text{MA}(1) \rightarrow y_t = \varepsilon_t - \theta \varepsilon_{t-1}$$

$$\text{invertible} \Rightarrow y_t + \theta y_{t-1} + \theta^2 y_{t-2} + \dots = \varepsilon_t$$

$$\text{por lo que } y_t = -\theta y_{t-1} - \theta^2 y_{t-2} - \dots + \varepsilon_t$$

$$E(y_{T+1} / \Omega_T) = -\theta y_T - \theta^2 y_{T-2} - \dots + 0$$

$$E(y_{T+2} / \Omega_T) = -\theta E(y_{T+1} / \Omega_T) - \theta^2 y_T - \dots = 0 \quad (\text{se anula})$$

$$\text{luego } E(y_{T+k} / \Omega_T) = 0 \text{ para } k \geq 2$$

$$\text{En general, para } \text{MA}(q) \quad E(y_{T+k} / \Omega_T) = 0 \text{ para } k > q$$

$$\text{ARMA}(1,1) \rightarrow Y_t = \delta + \phi Y_{t-1} + \varepsilon_t - \theta \varepsilon_{t-1}$$

$$E[Y_{T+1}/\Omega_T] = \delta + \phi Y_T + 0 - \theta \varepsilon_T$$

↑
En T se conoce

$$E[Y_{T+k}/\Omega_T] = (1 + \phi + \dots + \phi^{k-1})\delta + \phi^k Y_T - \phi^{k-1}\theta \varepsilon_T$$

$$k \rightarrow +\infty \Rightarrow \hat{Y}_{T+k} \rightarrow E(Y_t)$$

Intervalos de confianza para las predicciones

$$E[Y_{T+k}/Y_T] \pm \lambda_{\alpha} \hat{\sigma}_{\varepsilon_T}(k)$$

↑ Normal ← estimación

Predicción en un ARIMA

$d \neq 0 \Rightarrow$ Al tomar diferencias se ha pasado a un proceso estacionario, que es el que se ha estimado y sobre el que se han hecho las predicciones. Hay que deshacer el cambio.

Si $d = 1 \Rightarrow (1-L)Y_t = Y_t - Y_{t-1} = Z_t$ estacionario

~~Conocemos $\hat{Z}_{T+1}, \dots, \hat{Z}_{T+k}$~~
Conocemos Y_1, \dots, Y_T
 \Rightarrow Conocemos Z_1, \dots, Z_T

Predicimos $\hat{Z}_{T+1}, \dots, \hat{Z}_{T+k}$

$$E(Y_{T+1}/\Omega_T) = E(Z_{T+1}/\Omega_T) + Y_T$$

iterando

$$E(\bar{Y}_{T+k}/\Omega_T) = E(\bar{Z}_{T+k}/\Omega_T) + E(\bar{Z}_{T+k-1}/\Omega_T) + \dots + Y_T$$

Si $Z_t = \ln Y_t \leftarrow$ transf. logarítmica.

$$E(Y_{T+k}/\Omega_T) = \exp \left\{ E(Z_{T+k}/\Omega_T) + \frac{1}{2} \text{Var } e_T(k) \right\}$$

← error de predic.

\hookrightarrow el intervalo de confianza no será simétrico

$$\text{ARMA}(0,1) \times \text{ARMA}(0,1)_S = \text{MA}(1) \times \text{MA}(1)_S$$

$$\rightarrow Y_t = (1 - \theta_1 L) \cdot (1 - \oplus_1 L^S) \varepsilon_t$$

$$Y_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} - \oplus_1 \varepsilon_{t-S} - \theta_1 \oplus_1 \varepsilon_{t-(1+S)}$$

$$\text{ARMA}(0,2) \times \text{ARMA}(0,1)_S$$

$$Y_t = (1 - \theta_1 L - \theta_2 L^2) \cdot (1 - \oplus_1 L^S) \varepsilon_t =$$

$$= \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \oplus_1 \varepsilon_{t-S} + \theta_1 \oplus_1 \varepsilon_{t-(1+S)} + \theta_2 \oplus_1 \varepsilon_{t-(2+S)}$$

$$\text{ARMA}(0,1) \times \text{ARMA}(1,0)_S$$

$$(1 - \oplus_1 L^S) Y_t = (1 - \theta_1 L) \varepsilon_t$$

$$Y_t - \oplus_1 Y_{t-S} = \varepsilon_t - \theta_1 \varepsilon_{t-1}$$

$$\text{ARMA}(1,0) \times \text{ARMA}(0,1)_S$$

$$(1 - \phi_1 L) Y_t = (1 - \oplus_1 L^S) \varepsilon_t$$

$$Y_t - \phi_1 Y_{t-1} = \varepsilon_t - \oplus_1 \varepsilon_{t-S}$$

$$\text{ARMA}(1,0) \times \text{ARMA}(1,0)_S$$

$$(1 - \phi_1 L) \cdot (1 - \oplus_1 L^S) Y_t = \varepsilon_t$$

$$Y_t - \phi_1 Y_{t-1} - \oplus_1 Y_{t-S} + \phi_1 \oplus_1 Y_{t-(1+S)} = \varepsilon_t$$

$$\text{ARIMA}(p,d,q) \times \text{ARIMA}(P,D,Q)_S$$

$$\underset{P}{\phi(L)} \cdot \underset{P}{\oplus(L^S)} \cdot \Delta^d \Delta_S^D Y_t = \underset{Q}{\theta(L)} \cdot \underset{Q}{\oplus(L^S)} \cdot \varepsilon_t$$

ECONOMETRIA - T12

1-ARIMA (p,d,q)

- + Concepto
- + Especificación

(Paseo aleatorio,
Tendencia de variac. natural)

2- METODOLOGÍA de elaboración

- + Metodología ARIMA
- + Fases

3- F1: IDENTIFICACIÓN → $d, \lambda, \mu, \phi, \theta, p, q$

- + 1º Análisis de la estacionariedad

↳ en nivel (3) → d

↳ en pendiente → λ

↳ Identificación μ o δ

- + 2º Identificación de la parte estacional

↳ ~~ese~~ ϕ y θ

↳ Gradiente de AR, MA y ARMA

4- F2: ESTIMACIÓN → $\phi_i, \theta_i, \sigma_e^2, \delta$ o μ

- + Supuestos

- + Problemas

↳ Valores iniciales / Condición

↳ No condic.

↳ Model. no lineal en los coef. ($q \geq 1$)

- + Estimadores: MCO o MV.

5- F3: VALIDACIÓN

- + $\hat{\epsilon}_t$ ruido blanco → F1

+ W_t estac. e invariable → valores unit. y condic.

+ Coef. μ o $\delta \neq 0$ e incorrelac.

+ R^2 infc. alto

- + Modelo estable en futuro

6- F4: PREDICCIÓN

$$\hat{Y}_{T+K} = E[Y_{T+K} | \Omega_T]$$

- + AR(1)

CARRERA		
APELLIDOS		NOMBRE
ASIGNATURA	FECHA	GRUPO

1. DEFINICIÓN

Consideramos solamente procesos no estacionarios que fácilmente pueden transformarse en modelos estacionarios.

Ejemplo: Paseo aleatorio. $\rightarrow Y_t = Y_{t-1} + \epsilon_t$

Es un AR(1) con $\phi = 1 \Rightarrow$ no es estacionario.

Tomando ~~primeras~~ diferencias de primer orden 1 vez

$$w_t = \Delta Y_t = Y_t - Y_{t-1} = \epsilon_t \rightarrow \text{nido blanco}$$

El proceso Y_t se obtiene sumando, o integrando, el proceso w_t

$$Y_t = w_t + Y_{t-1} = w_t + w_{t-1} + Y_{t-2} = \dots = w_t + w_{t-1} + \dots$$

MODELOS INTEGRADOS son una clase de modelos que se pueden transformar en estacionarios mediante la toma de diferencias o de otro modo

son modelos que se pueden obtener mediante suma o integración de un proceso estacionario. También se les denominan modelos no estacionarios homogéneos.

ARIMA (p, d, q) \rightarrow tomando primeras diferencias d veces se obtiene un ARMA (p, q)

$I \equiv$ integrado

Y_t es ARIMA(p, d, q) si $(1-L)^d Y_t$ es ARMA(p, q).

$w_t = \Delta^d Y_t = (1-L)^d Y_t$ Como w_t es ARMA(p, q):

$$(1 - \phi_1 L - \dots - \phi_p L^p) w_t = (1 - \theta_1 L - \dots - \theta_q L^q) \epsilon_t$$

$$(1 - \phi_1 L - \dots - \phi_p L^p) (1-L)^d Y_t = (1 - \theta_1 L - \dots - \theta_q L^q) \epsilon_t$$

$$\Phi(L) (1-L)^d Y_t = \Theta(L) \epsilon_t$$

Situación: Variante de la s.t. viene afectada por una tendencia y esta tendencia no desaparece al tomar diferencias.

Transformación Box y Cox (1984)

$$Y_t(\lambda) = \begin{cases} \frac{Y_t^\lambda - 1}{\lambda} & \lambda \neq 0 \\ \ln Y_t & \lambda = 0 \end{cases}$$

Para $\lambda = 1 \rightarrow$ transformación \sim valores originales

$\lambda = 0 \rightarrow$ la primera transf. da una indet. % cuyo límite es $\ln Y$

Combinando una diferencia con la toma de logaritmos se obtiene la transformación $\Delta \ln Y_t$, muy útil si no se tiene en cuenta el problema de la estacionalidad.

$\Delta \ln Y_t \equiv$ tasa de variación natural

$$\Delta \ln Y_t = \ln Y_t - \ln Y_{t-1} = \ln \frac{Y_t}{Y_{t-1}}$$

$$\Delta \ln Y_t \simeq \dot{Y}_t \quad (\text{tasa de variac. relativa, } \frac{Y_t}{Y_{t-1}} - 1)$$

La tasa de variación natural es aditiva \equiv se puede obtener como suma de las tasas de variación natural de los intervalos en que está dividido el período.

$$\Delta \ln Y_1 + \Delta \ln Y_2 + \Delta \ln Y_3 + \dots = \ln \frac{Y_3}{Y_0}$$

METODOLOGÍA DE ELABORACIÓN 2. FASE DE IDENTIFICACIÓN


Metodología de elaboración

Una serie temporal se puede contemplar como una realización de un proceso estocástico.

Los modelos ARIMA, aunque son una clase particular de procesos estocásticos, pueden ser utilizados para describir el comportamiento de la mayor parte de las series económicas.

Se considerará que una serie temporal dada es una realización de un proceso específico $ARIMA(p, d, q)$, en el que están determinados numéricamente los parámetros $\phi_1, \dots, \phi_p, \theta_1, \dots, \theta_q, d, \lambda, \mu$ y σ_e^2 .

En la práctica, se parte de una serie temporal conocida (los valores observados de la magnitud a lo largo del tiempo) y se pretende determinar el modelo ARIMA que verosímilmente la haya podido generar.



Para efectuar inferencias se suele disponer de una o más realizaciones (series temporales). En Economía, hay que efectuarla ^{con} siempre en base a una sola realización.
a partir de

la elaboración de un modelo ARIMA consiste en la búsqueda de un proceso $ARIMA(p, d, q)$ que verosímilmente haya podido generar la serie temporal objeto de estudio. En la fase de elaboración se requiere utilizar un ordenador.

Fase 1: Identificación \rightarrow Especificación del modelo.

1º. Análisis de estacionariedad

(NO) es estacionaria \rightarrow transformaciones para hacerla

• Diferencia de primer orden $\rightarrow d$.

• Transformación Box y Cox $\rightarrow \lambda$.

¿considerar $\mu \neq 0$?

2º. Determinación de los órdenes del proceso ARIMA

• Parte autorregresiva \rightarrow ~~2~~ p

• Parte media móvil \rightarrow q

Fase 2: Estimación \rightarrow Estimación de los parámetros

• Estimación de $\phi_1 \dots \phi_p$

• Estimación de $\theta_1 \dots \theta_q$

• Estimación de σ_e^2

• $\frac{1}{2}$ Opcional: estimación de μ_w (media proceso estac.)

Una vez concluida la estimación, el proceso estacionario relacionado con el ARIMA que haya podido generar lo que puede:

$$\phi(L)(w_t - \mu_w) = \theta(L)\hat{\varepsilon}_t$$

donde $\hat{\varepsilon}_t$ se puede obtener a partir de los parámetros de la serie w_t y, si el modelo fuera adecuado, debería aproximarse al "ruido blanco" ε_t .

Fase 3: Validación \rightarrow ¿es el modelo adecuado?

Si $\hat{\varepsilon}_t$ se parece a un ruido blanco, el modelo obtenido en las fases anteriores es válido. En caso contrario, hay que empezar otra vez desde el principio.

Fase 4: Predicción \rightarrow Utilizar el modelo validado para pronosticar valores futuros.

Tb. tiene de validación del modelo, de manera que si existen discrepancias de carácter sistemático entre los valores pronosticados y los valores observados, se debería cuestionar la validez del modelo, y se debe proceder a reidentificar el modelo generador.

El principio de la parametrización escueta que proponen Box y Jenkins consiste en postular un modelo generador con el mínimo número de parámetros posibles, y ampliar este número sólo si es estrictamente necesario.

- Correlación entre y_t e y_{t-k}
- Ajustada por el efecto de los retardos intermedios ($y_{t-1}, y_{t-2}, \dots, y_{t-k-1}$)

CARRERA		
APELLIDOS		NOMBRE
ASIGNATURA	FECHA	GRUPO

3. FASE de IDENTIFICACIÓN

1. Identificación de modelos estacionarios } $\begin{matrix} P \\ q \end{matrix}$ } ARMA (p,q)

Función de autocorrelación estimada (FACE)

A partir de una muestra de tamaño N de valores de una serie estacionaria w_t , se puede calcular un coef. de autocorrelación muestral de orden c :

$$r_c = \frac{\sum_{t=c+1}^N (w_t - \bar{w})(w_{t-c} - \bar{w})}{\sum_{t=1}^N (w_t - \bar{w})^2}$$

la sucesión de valores de r_c , para $c = 1, 2, 3, \dots$ constituye el correlograma estimado o FACE. ↓ z retardo

A medida que crece el orden del retardo disminuye el nº de sumandos del numerador, por lo que no se recomienda calcular coef. de autocorrelación para $c \geq \frac{1}{3}N$ o $\frac{1}{4}N$.

Función de autocorrelación parcial teórica (FACPT)

y estimada (FACPE)

A diferencia de lo que ocurre en un MA, en un AR, de q orden la función de autocorrelación teórica empieza a decrecer a partir de un determinado retardo, pero nunca se hace 0.

FACPT $\rightarrow \phi_{11}, \phi_{22}, \phi_{33}, \dots, \phi_{pp}, \dots$

En AR(p) $\rightarrow \phi_{11} \dots \phi_{pp} \neq 0$ y $\phi_{p+1,p+1} = \phi_{p+2,p+2} = 0$

En MA(q) \rightarrow Decae de forma rápida a partir de q , pero nunca se hacen 0.

En un ARMA (p, q) tanto la FACPT como FACT tienen infinitos elementos $\neq 0$.

Función de autocorrelación parcial estimada (FACPE)

$$\hat{\phi}_{11}, \hat{\phi}_{22}, \dots$$

Puede contemplarse como la correlación parcial existente entre dos periodos ($\hat{\phi}_{kk} = \text{corr}(Y_t, Y_{t-k})$) cuando se han eliminado el efecto de las var. intermedias ($Y_{t-1}, Y_{t-2}, \dots, Y_{t-k+1}$)

$$AR(p) \rightarrow \hat{\phi}_{kk} = 0 \text{ para } k > p.$$

la identificación del modelo generador será tanto más fácil cuanto mayor sea el tamaño de la muestra. En las series cuyo n° de observaciones sea pequeño, la identificación con los instrumentos propuestos es muy difícil.

Resumen

Función de AutoCorrelación Técnica (FACT) En Novales (fas)

AR(p) \rightarrow Decrecimiento rápido de tipo geométrico puro y geométrico con atenuación de riques
sinusoidal o mezcla de varios tipos

MA(q) \rightarrow Se anula para retardos superiores a q.

ARMA(p, q) \rightarrow Primeros valores iniciales sin patrón fijo, seguidos por mezcla de oscilaciones sinusoidales y/o exponenciales amortiguadas.

Función de AutoCorrelación Parcial Técnica (FACPT) En Novales (fp)

AR(p) \rightarrow Se anula para retardos superiores a p.

MA(q) \rightarrow Decrecimiento rápido de tipo exponencial y/o sinusoidal

ARMA(p, q) \rightarrow Primeros valores iniciales sin patrón fijo
Mezcla de oscilaciones sinusoidales y/o exponenciales amortiguadas.

2º. Análisis de estacionariedad. ~~No estacionario en nivel~~
~~Si estacionario en primera~~

a) No estacionariedad en media: Identificación de (d)

Análisis visual del gráfico de la serie \rightarrow mirar si existe un valor en torno al cual la serie va oscilando pero no alejarse de forma permanente de dicho valor.

Examen de la FACE: Para un paseo aleatorio que arranque en un período fijo, ρ_{2t} se mantiene próx. a 1. Si los coef. de la FACE no descienden rápidamente, entonces la serie es no estacionaria.

Hay que tomar 1 diferencia y observar la FACE de la serie diferenciada, así hasta que decaiga.

En la práctica, basta con $d=1$ o $d=2$.

¿Qué pasa si el modelo se sobreparametriza? d elegido $> d$ bueno
El modelo será no invertible y con una var. no pr, pero siempre estacionario (se la parametrización se veía al estimar la parte MA, con algún θ próx. a 1).

Análisis de la variación: Calcular la variación de la serie original y de la serie sometida a diferentes diferencias, y elegir aquella con variación mínima.

Estas herramientas no dejan de ser ^{pruebas} informales poco rigurosas.
Contrastes de estacionariedad \rightarrow Contrastes de raíces unitarias (contraste de Dickey-Fuller).

b) No estacionariedad en variación: Identificación de (λ)

Series económicas que se extienden a lo largo de un período dilatado de tiempo y que están afectadas por una fuerte tendencia, \rightarrow transformación instantánea tipo Box y Cox, para obtener una serie estacionaria en variación y que al mismo tiempo tenga una distrib. normal.

En la práctica, las alternativas que se utilizan son $\lambda=0$ (tomar logaritmos naturales) y $\lambda=1$ (quedar igual).

Análisis visual del gráfico de la serie, para ver si se mantiene o no la dispersión en torno al nivel.
Si $t \rightarrow$ dispersión \uparrow , tener en (1.2.2).

Gráfico rango-media. Se divide la serie en varios intervalos, en cada uno se calcula la media (medida del nivel) y el rango (medida de dispersión).

Si los datos son estacionales, el intervalo se considera de longitud $=$ período estacional.

- Si los puntos están aprox. alineados en torno a una línea recta con pde ascendente \Rightarrow no son estacionales en varianza. Tómese en.
- Si el gráfico no muestran un esquema claro, o bien están alineados paralelos al eje $OX \Rightarrow$ no hay conf.

2º. Identificación del término independiente $\mu = E[Y_t]$ 1.0

Se trata de determinar si se incluye una media en el proceso $\{W_t\}$, $W_t(\mu)$, o alternativamente, un término indep. δ , en la especificación del proceso.

Teniendo en cuenta que en un proceso ARIMA los datos están autocorrelacionados, el estimador de la varianza muestral puede aproximarse por:

$$\hat{\sigma}_w^2 = \frac{S_w^2}{N} (1 + 2r_1 + 2r_2 + \dots + 2r_K)$$

siendo K tal que r_k son significativos. Se puede obtener un estimador negativo, no será aplicable.

1º. Problemas no estacionariedad

Heteroscedasticidad $\Rightarrow \ln Y_t \sim Y_t^{(A)}$ \sim homosc.

Modelo con $\mu \neq 0$ $Y_t^{(A)} - \mu \sim$ media 0

Modelo no estac. en nivel $\Rightarrow (1-L)^d (Y_t^{(A)} - \mu)$ estacionario

Llamamos $W_t = (1-L)^d (Y_t^{(A)} - \mu) \rightarrow$ ARMA (p, q)

2º. Identificar p y q

CARRERA			
APELLIDOS		NOMBRE	
ASIGNATURA	FECHA	GRUPO	

4. FASE de ESTIMACIÓN

En la fase de identificación, primero

Y_t no estacionario $\rightarrow W_t$ sí estacionario

$$W_t = (1-L)^d Y_t(x) \quad \text{ó} \quad W_t = (1-L)^d (Y_t(x) - \mu)$$

Después se identifican los órdenes de la parte autorregresiva (p) y de la parte de medias móviles (q)

$$W_t - \phi_1 W_{t-1} - \dots - \phi_p W_{t-p} = \varepsilon_t - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q} + \delta_w$$

Se ha incluido una δ_w , que se relaciona con la media

$$\mu_w = \frac{\delta_w}{1 - \phi_1 - \dots - \phi_p}$$

Alternativamente el proceso se puede expresar:

$$(W_t - \mu_w) - \phi_1 (W_{t-1} - \mu_w) - \dots - \phi_p (W_{t-p} - \mu_w) = \varepsilon_t - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q}$$

En la fase de estimación se trata de estimar los parámetros $\phi_1, \dots, \phi_p, \theta_1, \dots, \theta_q, \mu_w$ y σ_ε^2 .

Supuestos:

- $\varepsilon \rightarrow N(0, \sigma_\varepsilon^2 I)$
- El proceso W_t es estacionario
- El proceso W_t es invertible
- $\delta_w = 0 \Rightarrow \mu_w = 0$.

Los estimadores se obtienen por mínimos cuadrados o por máxima verosimilitud. En cualquier caso, la estimación de un modelo ARMA plantea el problema de:

- determinación valores iniciales
- modelos no lineales.

Hay dos enfoques distintos para arreglar el problema de los valores iniciales.

Enfoque condicional \rightarrow Se dan w_1, \dots, w_N

$$w_0, w_{-1}, \dots, w_{-p+1}$$

$$e_0, e_{-1}, \dots, e_{-q+1}$$

Enfoque ^w condicional \rightarrow Se dan w_1, \dots, w_N

Todo lo demás hay que estimarlo.

Si se verifica que $q \geq 1$ el modelo será no lineal en los coeficientes. En un modelo de este tipo no es posible obtener soluciones analíticas, habrá que utilizar métodos iterativos.

En la práctica, la fase de estimación es realizada por el ordenador, ya que los cálculos son excesivos y complejos.

MIRAR mejor

5. FASE de VALIDACIÓN

Una vez que se ha identificado el modelo y se han estimado los parámetros, nos planteamos si el modelo especificado en las dos fases anteriores es adecuado a los datos muestrales.

Un modelo válido debería cumplir:

- Residuos se comportan aprox. como ruido blanco.
- Modelo estimado estacionario e invertible.
- Los coeficientes son estadísticamente significativos y están poco correlacionados entre sí.
- Los coef. del modelo son suficientes para ^{explicar} representar la serie.
- El grado de ajuste es elevado comparado con otros modelos.

Si los residuos no se aproximan a un ruido blanco, el modelo debería rechazarse.

Análisis de los residuos

Los residuos tienen que comportarse como un ruido blanco, de media 0, por lo que la mayoría tienen que estar aprox. a 0.

Los residuos tienen que estar incorrelacionados. Esto se ve en la FACE y la FACPE, cuyos coeficientes no deben ser significativamente distintos de 0. En la práctica, se construyen bandas de confianza. Otra forma es realizar un contraste global.

Algunos autores proponen tomar diferencias de primer orden en los residuos y volver a calcular la FACE y la FACPE cuyo comportamiento se puede revisar.

Existen otros contrastes para revisar la heteroscedasticidad de la serie de residuos.

Análisis de los coef. estimados

En la salida de ordenador suele aparecer junto al coef. estimado, la desv. típica, el estadístico t , y el NSC de cada coef.

El estadístico t está construido bajo la hipótesis nula de que el parámetro es igual a 0, y seguirá una distrib. t_{N-k}
 $H_0: \phi_1 = 0 \rightarrow$ reducir para $\alpha = 5\%$ con $t > 2$
 $H_1: \phi_1 \neq 0$

Es importante comprobar si el modelo estimado es estacionario e invertible.

Factorizando la parte autorregresiva, si hay algún coeficiente próximo a 1, entonces el modelo es no estacionario \rightarrow tomar 1 dif.

Factorizando la parte de medias móviles, si algún coef. está próximo a 1, el modelo es no invertible \rightarrow sobreparametrización (sobrediferenciación)

Es conveniente revisar la matriz de correlación entre los coef. estimados para revisar si existe un problema de multicolinealidad \rightarrow ¿eliminar 1 parámetro?

Tb. se puede ver si el modelo mejora introduciendo parámetros adicionales.

Será mejor el modelo que mejor ajuste (R^2 y \bar{R}^2) (\bar{R}^2 penaliza los parámetros adicionales, evita la sobreparametrización).

Análisis de estabilidad \rightarrow el modelo estimado para el período muestral ¿sigue siendo válido para períodos futuros? Normalmente, a medida que se van efectuando nuevas observaciones se va comprobando si sigue siendo válido.

En el caso de que después de hacer los contrastes y análisis expuestos anteriormente se llega a la conclusión de que el modelo es no válido, hay que reformular el modelo.

En la reformulación se han de tener en cuenta los resultados de esta fase.

CARRERA		
APELLIDOS		NOMBRE
ASIGNATURA	FECHA	GRUPO

6. FASE de PREDICCIÓN

Una vez que se ha conseguido un modelo estimado compatible con los datos, la fase siguiente consiste en utilizar este modelo estimado en la predicción de valores futuros de la variable objeto de estudio.

A veces, resulta más cómodo escribir el modelo ARIMA de formas alternativas:

Partiendo de $\phi_p(L) A^d Y_t = \theta_q(L) \varepsilon_t$

Multiplicando la parte AR con la unit.

$$\phi(1 - \phi_1 L - \dots - \phi_p L^p) \underbrace{(1-L)(1-L)\dots(1-L)}_{d \text{ veces}} = 1 - \psi_1 L - \dots - \psi_{p+d} L^{p+d}$$

$\psi(L) \equiv$ coef. autorregresivos generalizados

ARIMA $\rightarrow \psi(L) Y_t = \theta(L) \varepsilon_t$

Las formas alternativas de predecir Y_{T+l} (conocido hasta T)

a) mediante un ARMA: $Y_{T+l} = \psi_1 Y_{T+l-1} + \psi_2 Y_{T+l-2} + \dots + \psi_{p+d} Y_{T+l-p} + \varepsilon_{T+l} - \theta_1 \varepsilon_{T+l-1} - \dots - \theta_q \varepsilon_{T+l-q}$

b) mediante un MA(∞): $\psi(L)\psi(L) = \theta(L) \rightarrow$ despejo $\psi(L)$.
donde $\psi(L) = 1 + \psi_1 L + \psi_2 L^2 + \dots$

$$Y_{T+l} = \psi(L) \varepsilon_{T+l} = \varepsilon_{T+l} + \psi_1 \varepsilon_{T+l-1} + \dots$$

c) mediante un AR(∞): $\psi(L) = \pi(L)\theta(L) \rightarrow$ despejo $\pi(L)$
donde $\pi(L) = 1 - \pi_1 L - \pi_2 L^2 - \dots$

$$Y_{T+l} = \sum_{j=1}^{\infty} \pi_j Y_{T+l-j} + \varepsilon_{T+l}$$

El predictor óptimo

En la obtención del predictor se supondrán conocidos los parámetros del modelo $\phi_1, \dots, \phi_p, \theta_1, \dots, \theta_q, \theta_b$, se suponen conocidos todos los ruidos presentes y pasado $\varepsilon_T, \varepsilon_{T-1}, \dots$

Como criterio de selección, se elegirá el predictor que minimice el ECM, $\tilde{Y}_{T+l|T} \rightarrow$ predictor óptimo /

$$E(Y_{T+l} - \tilde{Y}_{T+l|T})^2 \leq E(Y_{T+l} - \underset{\substack{\uparrow \\ \text{pred. arbitrario}}}{Y_{T+l,T}^*})^2$$

El predictor óptimo será un estimador lineal, función lineal de todos los valores conocidos de ε_t .

En general, para el cálculo de predicciones de valores futuros se utiliza el modelo en la forma original ARMA, donde la parte AR está constituida por los coef. autoregresivos generalizados.

Se obtiene de manera recursiva.

Se recomienda realizar un contraste de estabilidad estructural con los períodos de predicción.

CARRERA		
APELLIDOS		NOMBRE
ASIGNATURA	FECHA	GRUPO

PROCESOS NO ESTACIONARIOS

Solamente consideramos procesos no estacionarios que se puedan transformar en procesos estacionarios.

Paseo aleatorio

Es un AR(1) con $\phi_1 = 1$

$$Y_t = Y_{t-1} + \epsilon_t$$

De manera recursiva se puede expresar como

$$Y_t = \sum_{j=0}^{\infty} \epsilon_{t-j}$$

La variancia es infinita, el proceso es no estacionario

Sp. que el proceso se inicia en $-N+1$, tampoco es estacionario porque la variancia es \neq en cada periodo.

El coef. de autocorrelación depende del periodo de referencia, para t muy grande, está próximo a 1. Para t no está def.

El proceso puede transformarse en estacionario tomando una diferencia, diferencia de primer orden

$$w_t = \Delta Y_t = Y_t - Y_{t-1} = \epsilon_t \rightarrow \text{ruido blanco}$$

Para pasar de w_t a Y_t hay que integrar, por eso se llaman modelos integrados

$$Y_t = w_t + Y_{t-1} = w_t + w_{t-1} + Y_{t-2} = \dots = w_t + w_{t-1} + \dots$$

ARIMA (p, d, q), I = integrado.

Es un modelo integrado, de modo que tomando diferencias d veces se obtiene un modelo estacionario del tipo ARMA (p, q)

Ani, $W_t = \Delta^d Y_t = (1-L)^d Y_t$

Es decir,

$$\underbrace{(1 - \phi_1 L - \dots - \phi_p L^p)}_{\text{AR}(p)} \underbrace{(1-L)^d}_{\text{I}(d)} Y_t = \underbrace{(1 - \theta_1 L - \theta_2 L^2 - \dots - \theta_q L^q)}_{\text{MA}(q)} \varepsilon_t$$

En forma más compacta se ve:

$$\phi(L) (1-L)^d Y_t = \theta(L) \varepsilon_t$$

Transformación Box y Cox

La variación viene afectada por la tendencia, que no desaparece al tomar diferencias \rightarrow tomar logaritmos.

$$Y_t^{(\lambda)} = \begin{cases} \frac{Y_t^\lambda - 1}{\lambda} & \lambda \neq 0 \\ \ln Y_t & \lambda = 0 \end{cases}$$

$\lambda = 1 \rightarrow$ tomar valores originales

$\lambda = 0 \rightarrow$ indeterminación $\frac{0}{0}$. Regla L'Hôpital: $\lim_{\lambda \rightarrow 0} \frac{Y_t^\lambda - 1}{\lambda} = \lim_{\lambda \rightarrow 0} Y_t^\lambda \ln Y_t = \ln Y_t$

Combinando una diferencia con la toma de logaritmos, se obtiene la transformación $\ln Y_t \equiv$ tasa de variación natural, que es una aprox. de la tasa de variación relativa, y que tiene la ventaja de ser aditiva.

MODELOS ESTACIONALES

Datos que tienen oscilaciones estrictamente periódicas, con período inferior o igual a un año.

Modelos estacionales puros y estacionarios

AR(1) estacional, $AR(1)_s$

$$Y_t = \Phi_1 Y_{t-s} + \varepsilon_t$$

Sólo existe relación entre las observaciones separadas por múltiplos de s períodos. En realidad, coexisten s procesos autorregresivos independientes entre sí, pero con igual Φ_1 .

CARRERA		
APELLIDOS		NOMBRE
ASIGNATURA	FECHA	GRUPO

$$AR(1)_S \rightarrow Y_t = \Phi_1 Y_{t-1} + \varepsilon_t$$

$$AR(2)_S \rightarrow Y_t = \Phi_1 Y_{t-1} + \Phi_2 Y_{t-2} + \varepsilon_t$$

$$MA(1)_S \rightarrow Y_t = \varepsilon_t - \omega_1 \varepsilon_{t-1}$$

$$MA(2)_S \rightarrow Y_t = \varepsilon_t - \omega_1 \varepsilon_{t-1} - \omega_2 \varepsilon_{t-2}$$

$$ARMA(1,1)_S \rightarrow Y_t - \Phi_1 Y_{t-1} = \varepsilon_t - \omega_1 \varepsilon_{t-1}$$

Modelos mixto multiplicativo

$$ARMA(p,q) \times ARMA(P,Q)_S \rightarrow \Phi(L) \bar{\Phi}(L^S) Y_t = \Theta(L) \bar{\omega}(L^S) \varepsilon_t$$

$$\begin{aligned} MA(1) \times MA(1)_{S=12} &\rightarrow Y_t = \cancel{\varepsilon_t} (1 - \theta_1 L) (1 - \omega_1 L^{12}) \varepsilon_t \\ &= (1 - \theta_1 L - \theta_1 \omega_1 L^{13} - \omega_1 L^{12}) \varepsilon_t \\ &= \varepsilon_t - \theta_1 \varepsilon_{t-1} - \omega_1 \varepsilon_{t-12} - \theta_1 \omega_1 \varepsilon_{t-13} \end{aligned}$$

$$ARMA(0,1) \times ARMA(0,1)_S = MA(1) \times MA(1)_S$$

$$ARMA(0,2) \times ARMA(0,1)_S$$

$$(1) \cdot (1) Y_t = (1 - \theta_1 L - \theta_2 L^2) (1 - \omega_1 L^S) \varepsilon_t$$

$$ARMA(0,1) \times ARMA(1,0)_S$$

$$(1) (1 - \Phi_1 L^S) Y_t = (1 - \theta_1 L) \cdot (1) \varepsilon_t$$

$$ARMA(1,0) \times ARMA(1,0)_S$$

$$(1 - \phi_1 L) \cdot (1 - \Phi_1 L^S) Y_t = \varepsilon_t$$

Modelos estacionales no estacionarios

ARIMA(0,1

$$\begin{aligned} &ARIMA(p,d,q) \times ARIMA(P,D,Q)_S (1-L)^{SD} \\ &(1 - \phi_1 L - \dots - \phi_p L^p) (1-L)^d (1 - \Phi_1 L^S - \dots - \Phi_P L^{PS}) Y_t = (1 - \theta_1 L - \dots - \theta_q L^q) \varepsilon_t \end{aligned}$$

CARRERA		
APELLIDOS		NOMBRE
ASIGNATURA	FECHA	GRUPO

$$AR(1) \rightarrow Y_t = 0.8 Y_{t-1} + \varepsilon_t \quad / \quad \sigma_\varepsilon^2 = 2$$

Estacionario? Si, porque $|0.8| < 1$.

Invertible? Todos los AR son invertibles

$$\begin{aligned} \gamma_0 &= E[Y_t Y_t] = E[(0.8 Y_{t-1} + \varepsilon_t)(0.8 Y_{t-1} + \varepsilon_t)] = \\ &= 0.64 E[Y_{t-1} Y_{t-1}] + 0 + 2 \end{aligned}$$

$$(1 - 0.64) \gamma_0 = 2 \rightarrow \gamma_0 = \frac{2}{1 - 0.64} = 5.56$$

$$\gamma_1 = E[Y_t Y_{t-1}] = E[(0.8 Y_{t-1} + \varepsilon_t) Y_{t-1}] = 0.8 \gamma_0 + 0$$

$$\begin{aligned} \gamma_2 &= E[Y_t Y_{t-2}] = E[(0.8 Y_{t-1} + \varepsilon_t) Y_{t-2}] = \\ &= E[0.8(0.8 Y_{t-2} + \varepsilon_{t-1}) + \varepsilon_t) Y_{t-2}] = \\ &= 0.8^2 \gamma_0 = 0.8 \gamma_1 \end{aligned}$$

$$\rho_0 = 1, \quad \rho_1 = \frac{\gamma_1}{\gamma_0} = \quad \text{ó bien } \rho_1 = \phi_1 \rho_0$$

$$\pi_A(+\infty)$$

$$AR(1) \text{ y } \psi(L) = \pi_A(\infty)$$

$$Y_t = 0.8 Y_{t-1} + \varepsilon_t$$

$$Y_t = 0.8 Y$$

$$Y_t - 0.8 Y_{t-1} = \varepsilon_t$$

$$MA(1) \rightarrow Y_t = \varepsilon_t - 0.9\varepsilon_{t-1} \quad ; \quad \sigma_\varepsilon^2 = 4$$

¿Estacionario? Todos los MA son estacionarios de orden finito

¿Invertible? $|0.9| < 1$ Sí.

$$\begin{aligned} \gamma_0 &= E[Y_t Y_t] = E[(\varepsilon_t - 0.9\varepsilon_{t-1})(\varepsilon_t - 0.9\varepsilon_{t-1})] = \\ &= \sigma_\varepsilon^2 - 0 - 0 + 0.9^2 \sigma_\varepsilon^2 = \\ &= (1 + 0.81) \sigma_\varepsilon^2 \end{aligned}$$

$$\gamma_1 = E[Y_t Y_{t-1}] = E[(\varepsilon_t - 0.9\varepsilon_{t-1})Y_{t-1}] = 0 - 0.9 \sigma_\varepsilon^2$$

\downarrow
 $\varepsilon_{t-1} - 0.9\varepsilon_{t-2}$

$$\gamma_2 = E[Y_t Y_{t-2}] = 0$$

$$\rho_0 = 1 \quad ; \quad \rho_1 = \frac{\gamma_1}{\gamma_0} = \frac{-0.9 \sigma_\varepsilon^2}{1 + 0.81 \sigma_\varepsilon^2} \quad ; \quad \rho_2 = \dots = \rho_5 = 0$$

$$AR(2) \rightarrow Y_t = 0.6Y_{t-1} + 0.3Y_{t-2} + \varepsilon_t \quad / \quad \sigma_\varepsilon^2 = 3$$

los módulos de las raíces de la ec. características tienen que ser < 1 .

~~$$1 - 0.6\lambda + 0.3\lambda^2 = 0$$~~

$$\lambda^2 - 0.6\lambda + 0.3 = 0$$

$$\lambda = \frac{0.6 \pm \sqrt{0.36 - 1.2}}{2} = 0.6 \pm$$

otra forma, $1 - 0.6L + 0.3L^2 = 0 \quad \leftarrow \begin{matrix} 1.08 \\ -3.68 \end{matrix}$ fuera del círculo unidad