

# ESTAD - T14 . DISTR. MULTINOMIAL .

## DISTR. NORMAL MULTIVARIANTE.

## PROPIEDADES. (incompleto, falta demostraciones)

### 1- DISTRIB. MULTINOMIAL , Multinomial $(n, p_1, \dots, p_k)$

la distrib. multinomial es una distribución discreta multivar.

se puede considerar una generalización de la Binomial, ya que el n.º de resultados posibles (Éxito/Fracaso en la Binomial) es mayor o igual que 3 (pero fijo?).

Si consideramos un experimento aleatorio donde los resultados posibles constituyen una partición del espacio muestral:

$$A_1, A_2, \dots, A_k \quad \text{tq} \quad E = A_1 \cup A_2 \cup \dots \cup A_k$$

$$A_i \cap A_j = \emptyset, \quad \forall i \neq j$$

y designamos por  $p_1, \dots, p_k$  las probabilidades de los diferentes sucesos:  $P(A_i) = p_i, \quad i = 1, \dots, k$

$$\text{bien definido} \rightarrow \sum_{i=1}^k p_i = \sum_{i=1}^k P(A_i) = P\left(\bigcup_{i=1}^k A_i\right) = P(E) = 1$$

El experimento consiste en la realización  $n$  veces de la misma prueba de manera independiente, donde la prob. de ocurrencia se mantiene constante. la variable aleatoria multidimensional que agrupa las v.a. unidim. que miden el n.º de veces que aparece cada resultado ~~es~~ sigue una distribución multinomial.

$$\xi = (\xi_1, \dots, \xi_k) \rightarrow \text{Multinomial}(n, p_1, \dots, p_k)$$

donde  $\xi_i \equiv$  n.º veces que aparece  $A_i$

$$\xi_i \rightarrow B(n, p_i) \quad ??$$

Conceptualmente, un fenómeno se distribuye con arreglo a una distrib. multinomial si:

- 1- El experimento consiste en la realización de  $n$  ensayos.
  - 2- Los resultados constituyen una partición del espacio muestral.
  - ~~3- Cada resultado lleva asociado una probab. de ocurrencia~~
  - 3- la probab. de ocurrencia es una  $p_i$
  - 4- la probab. permanecen constantes a lo largo de todo el experimento.
  - 5- los ensayos son indep. entre sí.
- la distrib. multinomial depende de  $k+1$  parámetros, el n.º de ensayos y la probab. de ocurrencia de cada suceso.  $(n, p_1, \dots, p_k)$

Definición:  $\mathbf{X} \equiv n^\circ$  de veces que aparece cada uno de los posibles resultados  $A_i$ ,  $i=1, \dots, k$ , cuando se repite  $n$  veces la misma prueba de manera independiente.

Función de cuantía:

$$P(\mathbf{X} = (x_1, x_2, \dots, x_k)) = \overbrace{PR_{x_1, x_2, \dots, x_k}^n}^{\text{Combinatoria}} \cdot \overbrace{P(\mathbf{X}_1 = x_1, \mathbf{X}_2 = x_2, \dots, \mathbf{X}_k = x_k)}^{\text{1 opción concreta}}$$

$$= \frac{n!}{x_1! \cdot \dots \cdot x_k!} \cdot \underbrace{P(\mathbf{X}_1 = x_1) \cdot P(\mathbf{X}_2 = x_2) \cdot \dots \cdot P(\mathbf{X}_k = x_k)}_{\text{indep.}}$$

$$= \frac{n!}{x_1! \cdot \dots \cdot x_k!} \cdot p_1^{x_1} \cdot p_2^{x_2} \cdot \dots \cdot p_k^{x_k}$$

para  $x_i = 0, 1, \dots, n$  /  $\sum_{i=1}^k x_i = n$

Efectivamente, es una función de probabilidad (está bien definida) porque:

$$P(x_1, \dots, x_k) \geq 0, \quad \forall (x_1, \dots, x_k)$$

$$\begin{aligned} \sum_{x_1} \dots \sum_{x_k} P(x_1, \dots, x_k) &= \sum_{x_1} \dots \sum_{x_k} \frac{n!}{x_1! \dots x_k!} p_1^{x_1} \dots p_k^{x_k} = \\ &= (p_1 + \dots + p_k)^n = 1^n = 1 \end{aligned}$$

Función de distribución: Probabilidad acumulada

$$\begin{aligned} F(x_1^1, x_2^2, \dots, x_k^k) &= P(S_1 \leq x_1^1, S_2 \leq x_2^2, \dots, S_k \leq x_k^k) = \\ &= \sum_{x_1 \leq x_1^1} \sum_{x_2 \leq x_2^2} \dots \sum_{x_k \leq x_k^k} P(x_1, \dots, x_k) = \\ &= \sum_{x_1 \leq x_1^1} \dots \sum_{x_k \leq x_k^k} \frac{n!}{x_1! \dots x_k!} p_1^{x_1} \dots p_k^{x_k} \end{aligned}$$

para  $x_i = 0, 1, \dots, n$  / tq  $\sum_{i=1}^k x_i = n$

Características  $t = (t_1, \dots, t_k)$

Función característica,  $\psi(t) = E[e^{it_1 S_1 + \dots + it_k S_k}] =$

$$= \sum_{x_1} \dots \sum_{x_k} e^{it_1 x_1 + \dots + it_k x_k} \cdot \frac{n!}{x_1! \dots x_k!} p_1^{x_1} \dots p_k^{x_k} =$$

$$= \sum_{x_1} \dots \sum_{x_k} \frac{n!}{x_1! \dots x_k!} (e^{it_1} p_1)^{x_1} \cdot (e^{it_2} p_2)^{x_2} \cdot \dots \cdot (e^{it_k} p_k)^{x_k} =$$

$$= (e^{it_1} p_1 + \dots + e^{it_k} p_k)^{x_1 + \dots + x_k} = \sum_{j=1}^k (p_j e^{it_j})^n$$

$$\psi(t) = \sum_{j=1}^k (p_j e^{it_j})^n$$

fórmula de Leibniz

$$\underline{\text{Esperanza}} = \alpha_1 = \frac{1}{i} \left| \frac{\partial \varphi(t)}{\partial t} \right|_{t=0}$$

Al ser una var. multidimensional, tendrá tantas esperanzas como posibilidades presente el experimento.

La esperanza  $\alpha_i$  será el momento respecto al origen de orden 1, marginal de la var.  $\xi_i$ .

$$\varphi(t_j) = \varphi(0, \dots, t_j, \dots, 0) = (p_1 + \dots + p_j e^{it_j} + \dots + p_k)^n$$

$$\frac{\partial \varphi(t_j)}{\partial t_j} = n(p_1 + \dots + p_j e^{it_j} + \dots + p_k)^{n-1} \cdot p_j e^{it_j} \cdot i = n i p_j e^{it_j} (\dots)$$

$$\left. \frac{\partial \varphi(t_j)}{\partial t_j} \right|_{t_j=0} = n \cdot i \cdot p_j \underbrace{(p_1 + \dots + p_j + \dots + p_k)}_{1}^{n-1} = n i \cdot p_j$$

$$\frac{1}{i} \left| \frac{\partial \varphi(t_j)}{\partial t_j} \right|_{t=0} = n p_j$$

Esperanza de  $\xi_i \rightarrow E[\xi_i] = n p_i$  <sup>caso es binomial</sup>,  $i = 1 \dots k$

$$\underline{\text{Varianza}} = \mu_2 = \alpha_2 - \alpha_1^2$$

$$\alpha_2 = \frac{1}{i^2} \left| \frac{\partial^2 \varphi(t)}{\partial t^2} \right|_{t=0}$$

$$\begin{aligned} \frac{\partial^2 \varphi(t_j)}{\partial t_j^2} &= n i^2 p_j e^{it_j} (p_1 + \dots + p_j e^{it_j} + \dots + p_k)^{n-1} + \\ &+ n i p_j e^{it_j} (n-1) (p_1 + \dots + p_j e^{it_j} + \dots + p_k)^{n-2} \cdot i p_j e^{it_j} = \end{aligned}$$

$$\left. \frac{\partial^2 \varphi(t_j)}{\partial t_j^2} \right|_{t=0} = n i^2 p_j (p_1 + \dots + p_k)^{n-1} + n i p_j (n-1) (p_1 + \dots + p_k)^{n-2} \cdot i p_j =$$

$$= n i^2 p_j + n(n-1) i^2 p_j^2$$

$$\frac{1}{i^2} \left| \frac{\partial^2 \varphi(t_j)}{\partial t_j^2} \right|_{t=0} = n p_j + n(n-1) p_j^2 = n^2 p_j^2 - n p_j^2 + n p_j$$

$$\text{Ani, } \text{Var}(\xi_j) = \cancel{n^2 p_j^2} - n p_j^2 + n p_j - (\cancel{n p_j})^2 = \\ = n p_j - n p_j^2 = n p_j (1 - p_j) \quad , \text{ para } j = 1 \dots k$$

Covarianza ,  $\mu_{11} = \alpha_{11} - \alpha_{10} \alpha_{01}$

$$\text{Cov}(\xi_i, \xi_j) = E(\xi_i \cdot \xi_j) - E(\xi_i) \cdot E(\xi_j) = \boxed{-n p_i p_j}$$

$$E(\xi_i \cdot \xi_j) = \frac{1}{i^2} \left| \frac{\partial^2 \varphi(t_i, t_j)}{\partial t_i \partial t_j} \right|_{t_i=t_j=0} \quad \begin{matrix} \text{utilizando } \alpha_2 \\ \downarrow \\ n^2 p_i p_j - n p_i p_j \end{matrix}$$

$$\text{Cov}(\xi_i, \xi_j) = \cancel{n^2 p_i p_j} - n p_i p_j - \cancel{n^2 p_i p_j} = -n p_i p_j$$

$$\frac{\partial \varphi(t_i, t_j)}{\partial t_i} = n i p_i e^{it_i} (p_i + \dots + p_i e^{it_i} + \dots + p_j e^{it_j} + \dots + p_k)^{n-1}$$

$$\frac{\partial^2 \varphi(t_i, t_j)}{\partial t_i \partial t_j} = n i p_i e^{it_i} (n-1) (p_i + \dots + p_i e^{it_i} + \dots + p_j e^{it_j} + \dots + p_k)^{n-2} \cdot p_j e^{it_j}$$

$$\frac{1}{i^2} \left| \frac{\partial^2 \varphi(t_i, t_j)}{\partial t_i \partial t_j} \right|_{t_i=t_j=0} = \frac{1}{i^2} n i^2 p_i (n-1) p_j = n^2 p_i p_j - n p_i p_j$$

## PROPIEDADES

P1  $\rightarrow$  Propiedad reproductiva: La suma de dos multinomiales indep. con las mismas probabilidades  $p_b$  es multinomial.

$$\left. \begin{array}{l} \xi \rightarrow M(n, p_1 \dots p_k) \\ \eta \rightarrow M(m, p_1 \dots p_k) \end{array} \right\} \xi = \xi + \eta \rightarrow M(n+m, p_1 \dots p_k)$$

Dem: Al ser distribuciones independientes, la función característica de la suma es el producto de las funciones caract. individuales que, al ser un producto de potencias con la misma base es la base con la suma de los exponentes.

$$\begin{aligned}\varphi_{\xi+\eta}(t_1, \dots, t_k) &= E[e^{it_1(x_1+y_1)+\dots+it_k(x_k+y_k)}] = \\ &= E[e^{it_1x_1+\dots+it_kx_k}] \cdot E[e^{it_1y_1+\dots+it_ky_k}] = \\ &= \left(\sum_{i=1}^k p_i e^{it_i}\right)^n \cdot \left(\sum_{i=1}^k p_i e^{it_i}\right)^m = \left(\sum_{i=1}^k p_i e^{it_i}\right)^{n+m}\end{aligned}$$

P2  $\Rightarrow$  La distribución multinomial es la distribución límite de la distrib. hipergeométrica multivariante.

$$HM(N; n, p_1, \dots, p_k) \xrightarrow{N \rightarrow +\infty} M(n, p_1, \dots, p_k)$$

$N$  = tamaño poblacional =  $n^0$  individuos, antes de realizar la  $1^a$  extracción sin reposar.

$n$  =  $n^0$  extracciones

## 2 - DISTRIB. NORMAL MULTIVARIANTE.

### a) Distrib. normal bidimensional

Definición: Una variable aleatoria bidimensional  $(\xi_1, \xi_2)$  de tipo continuo sigue una distrib. normal bivalente de parámetros:  $\mu_1$  y  $\mu_2$   $-\infty < \mu_i < +\infty$   
 $\sigma_1$  y  $\sigma_2$   $\sigma_i > 0$   
 $\rho$   $-1 < \rho < 1$  ← IMPORTANTE ( $\rho \neq \pm 1$ )

si su función de densidad es:

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \cdot e^{-\frac{1}{2(1-\rho^2)} \left[ \left( \frac{x_1-\mu_1}{\sigma_1} \right)^2 - 2\rho \left( \frac{x_1-\mu_1}{\sigma_1} \right) \left( \frac{x_2-\mu_2}{\sigma_2} \right) + \left( \frac{x_2-\mu_2}{\sigma_2} \right)^2 \right]}$$

Una expresión equivalente es:



$$f(x_1, x_2) = \frac{1}{2\pi\sqrt{|\Sigma|}} \cdot e^{-\frac{1}{2}(x-\mu)'\Sigma^{-1}(x-\mu)}, \text{ donde:}$$

$$x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}, \quad \mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} \quad \text{y} \quad \Sigma = E \left[ (x-\mu)_{2 \times 1} (x-\mu)_{1 \times 2}' \right] =$$

$$= \begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{pmatrix} \quad \left\{ \begin{array}{l} \text{matriz de} \\ \text{var.-cov.} \end{array} \right.$$

De manera abreviada se puede expresar la normal bivalente como  $N_2(\mu, \Sigma)$  donde  $\mu \equiv$  vector medias  
 $\Sigma \equiv$  matriz var.-cov.,  $|\Sigma| \neq 0$

Gráficamente, la campana de Gauss  $\uparrow$  en el plano pasa a ser una montaña en el espacio.



la probabilidad conjunta de que la v.a. bidimensional  $(\xi_1, \xi_2)$  tome valores en una región  $R$  ( $R = \text{intervalo } \mathbb{R}^2$ ) viene dado por:

$$R = \{ (x_1, x_2) \in \mathbb{R}^2 / a_1 \leq x_1 \leq b_1, a_2 \leq x_2 \leq b_2 \}$$

$$P((\xi_1, \xi_2) \in R) = P(a_1 \leq x_1 \leq b_1, a_2 \leq x_2 \leq b_2) =$$

$$= \int_{a_1}^{b_1} \int_{a_2}^{b_2} f(x_1, x_2) dx_1 dx_2 \quad \leftarrow \text{volumen comprendido entre la superficie y } R.$$

Función característica conjunta

$$\varphi(t_1, t_2) = e^{i(\mu_1 t_1 + \mu_2 t_2) - \frac{1}{2}(t_1^2 \sigma_1^2 + t_2^2 \sigma_2^2 - 2\rho \sigma_1 \sigma_2 t_1 t_2)}$$

Por las propiedades de f. característica sabemos que:

$$\varphi(t_1, 0) = \varphi_{\xi_1}(t) = e^{i\mu_1 t_1 - \frac{1}{2}t_1^2 \sigma_1^2}$$

$$\varphi(0, t_2) = \varphi_{\xi_2}(t) = e^{i\mu_2 t_2 - \frac{1}{2}t_2^2 \sigma_2^2} \quad \left\{ \begin{array}{l} \text{f. características} \\ \text{de las distrib. marginales} \end{array} \right.$$

las f. características de las distrib. marginales corresponden a la f. característica de una Normal unidimensional, por lo que los parámetros de la distrib. conjunta cobran significado:

$\mu_i \rightarrow$  media marginal de  $\xi_i$

$\sigma_i \rightarrow$  desviación típica de  $\xi_i$

$\rho \rightarrow$  coef. correlación de  $\xi_1$  y  $\xi_2$

$\rho = \frac{\text{COV}}{\sigma_1 \sigma_2}$   
 $\text{COV} = \mu_{11} = \alpha_{11} - \alpha_{10}\alpha_{01}$   
 Hay que calcular  $\alpha_{11} = \frac{\partial^2 \varphi}{\partial t_1 \partial t_2} \Big|_{t_1=t_2=0}$   
**MIRAR ATRAS**

Funciones de densidad marginales

$$f_1(x_1) = \frac{1}{\sigma_1 \sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x_1 - \mu_1}{\sigma_1}\right)^2} \quad -\infty < x_1 < +\infty$$

$$f_2(x_2) = \frac{1}{\sigma_2 \sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x_2 - \mu_2}{\sigma_2}\right)^2} \quad -\infty < x_2 < +\infty$$



Distribuciones condicionales

$$f(y/x_1) = \frac{f(x_1, x_2)}{f_1(x_1)} = \frac{\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \cdot e^{-\frac{1}{2(1-\rho^2)} \left[ \left(\frac{x_1-\mu_1}{\sigma_1}\right)^2 - 2\rho\frac{(x_1-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \left(\frac{y-\mu_2}{\sigma_2}\right)^2 \right]}}{\frac{1}{\sigma_1\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x_1-\mu_1}{\sigma_1}\right)^2}}$$

$$= \frac{1}{\sigma_2\sqrt{1-\rho^2}\sqrt{2\pi}} \cdot e^{-\frac{1}{2(1-\rho^2)}\sigma_2^2 \left[ x_2 - \left( \mu_2 + \rho \frac{\sigma_2}{\sigma_1} (x_1 - \mu_1) \right) \right]^2}$$

que es la función de densidad de una distrib. normal  
de media  $\rightarrow \mu_2 + \rho \frac{\sigma_2}{\sigma_1} (x_1 - \mu_1)$

de desv. típica  $\rightarrow \sigma_2\sqrt{1-\rho^2}$

Observación  $\rightarrow$  Normal bivaariante  $\Rightarrow$   $\left\{ \begin{array}{l} \text{marginales} \\ \text{condicionales} \end{array} \right\}$  normales univariates

## PROPIEDADES

P1  $\rightarrow$  Independencia: Si  $\xi_1$  y  $\xi_2$  son indep, entonces el coeficiente de correlación lineal es nulo,  $\rho=0$ , y la función de densidad conjunta queda

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2} e^{-\frac{1}{2} \left[ \left(\frac{x-\mu_1}{\sigma_1}\right)^2 + \left(\frac{y-\mu_2}{\sigma_2}\right)^2 \right]}$$

que verifica  $f(x, y) = f_1(x) \cdot f_2(y)$

o.e.:  $(\xi_1, \xi_2)$  indep  $\xrightarrow{(\sigma_{12}=0)} \rho=0$

$\leftarrow$   
sólo en el  
caso Normal

Obs  $\rightarrow$  Partiendo de dos distrib. normales no independientes, siempre es posible obtener independencia rotando los ejes.

P2  $\rightarrow$  Dada  $(\xi_1, \xi_2)$  una v.a. bidimensional, la combinación lineal de sus componentes es una normal unidimensional.

P3  $\rightarrow$  Sean  $\xi_1, \dots, \xi_n$  v.a.i.i.d  $N(\mu_i, \sigma_i^2)$ .  
 Definimos dos variables combinaciones lineales de las primeras (con  $\neq$ s coef, no todos nulos)  
 $\eta = \sum a_i \xi_i$  ,  $\gamma = \sum b_i \xi_i$   
 la función de densidad conjunta de  $(\eta, \gamma)$  es la de una normal bidimensional.

### Consideraciones sobre $\rho$

$-1 < \rho < 1 \Rightarrow \Sigma$  no singular  $\Rightarrow \exists$  f. densidad conjunta  
 $\exists$  f. características conjuntas

$|\rho| = 1 \Rightarrow \rho = \pm 1 \Rightarrow \Sigma$  singular  $\Rightarrow \nexists$  f. densidad conjunta  
 $\exists$  f. característica c/jk (nunca)  
 $\downarrow$   
 distrib. degenerada

## b) Distribución normal n-dimensional

Podemos generalizar lo visto anteriormente con dos variables al caso de más de dos.

$(X_1, \dots, X_n)$  es una v.a. normal multivariante si tiene por función de densidad conjunta:

$$f(x_1, \dots, x_n) = \frac{1}{\sqrt{(2\pi)^n \cdot |\Sigma|}} \cdot e^{-\frac{1}{2} (X-\mu)^T \Sigma^{-1} (X-\mu)}$$

donde :  $X = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$  ;  $\mu = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_n \end{pmatrix}$  ,  $\Sigma = \begin{pmatrix} \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1n} \\ \vdots & \sigma_2^2 & & \\ \vdots & & \ddots & \\ \sigma_{n1} & & & \sigma_n^2 \end{pmatrix}$