

ESTAD - T21. ESTIMACIÓN PUNTUAL II.

①

ESTIMADORES de MÍNIMA VARIANZA.

ESTIMADORES EFICIENTES

ESTIMADORES ROBUSTOS.

ESTIMADORES BAYESIANOS.

0. INFERENCIA. INTRODUCCIÓN

1. ~~ESTIMACIÓN PUNTUAL I.~~ (Igual fue T20)

Recordemos brevemente que la inferencia estadística consiste en ~~generalizar~~ sacar conclusiones sobre la población que nos interesa estudiar a partir de ~~de~~ la información que nos proporciona una muestra aleatoria basándonos en la Teoría de la Probabilidad.

Si estamos interesados en ~~en~~ estudiar el valor de una característica poblacional, θ , la inferencia que podemos utilizar es:

- Estimación,
- Contratación

La Estimación consiste en dar un valor aproximado del parámetro poblacional a partir de la información ~~proporcionada~~ muestral.

La Contratación consiste en formular una conjetura (hipótesis) sobre el valor del parámetro poblacional y utilizar la inform. muestral para aceptar o rechazar dicho hipótesis.

En el caso de la estimación, se puede aproximar:

- Estim. puntual \rightarrow valor concreto
- Estim. por intervalos de confianza \rightarrow intervalo


En ambos métodos se utiliza un estadístico (función real de la muestra) para estimar.

La ventaja de la estimación puntual es que da un valor concreto del estimador que puede sustituirse directamente en el parámetro, pero sólo cuando con la propiedad de consistencia. La ventaja de la estimación por intervalos es que el intervalo va acompañado de un grado de confianza de que el verdadero valor del parámetro se encuentre dentro del intervalo, pero no es conveniente si se ofrece infinitas soluciones.

J - ESTIMACIÓN PUNTUAL I.

La estimación puntual consiste en obtener un único número, calculado a partir de las observaciones muestrales, y que es utilizado como estimación del parámetro poblacional θ . Se le llama estimación puntual porque a ese $\hat{\theta}$, que se utiliza como estimación puntual de θ , se le puede asignar un punto de la recta real.

Esquema de la estimac. puntual:



Para una población ξ (realización de una v.a.), representada a partir de su función de distribución $F(x, \theta)$, que depende de un parámetro θ cuyo valor concreto se desconoce, se toma una muestra aleatoria (normalmente en poblac. infinitas se utiliza u.a.s.) con n elementos que, al ser el muestreo aleatorio tb será una v.a. A partir de la muestra se construye un estadístico (q depende del parámetro) que seguirá siendo una v.a. que se utiliza para estimar el parámetro, por eso se llama estimador.

Para una muestra concreta se obtendrá un ~~valor concreto~~ ^{valor concreto} del ~~estimador~~ ^{estimador}, que recibe el nombre de estimación puntual del parámetro poblacional.

Antes de continuar, merece la pena detenerse en los tres conceptos mencionados anteriormente para no confundirlos.

Parámetro \rightarrow Constante con valor desconocido.
~~Relacionado~~ ^{Característico} poblacional, no depende de la muestra y es único (\neq muestras, 1 parámetro).

Estimador \rightarrow Estadístico ^{función de la muestra} que se utiliza para ofrecer una aproximación del parámetro desconocido.
 Es una variable aleatoria, no una constante.

Estimación \rightarrow Valor de la v.a. estimador para una muestra concreta \rightarrow es una de.
 \neq muestras, $=$ estimador $\Rightarrow \neq$ estimaciones

Para seleccionar el estadístico que utilizaremos como estimador del parámetro poblacional tendremos en cuenta las propiedades de la distribución muestral del estadístico, por lo que:

- 1º. Estudiar distribución de los estad. en el muestreo.
- 2º. Conocer las propiedades deseables de los estimadores puntuales, para estudiar su bondad.
- 3º. Métodos de obtención

Afortunadamente, las propiedades y los métodos nos ayudan a elegir los estimadores que se nos ocurren de manera natural.

Para la media poblacional μ , la media muestral \bar{x}

Para la varianza poblacional σ^2 , una corrección de la varianza muestral, la covarianza muestral (en ambos infinitos de igual).

Para la proporción poblacional P , la proporción muestral p .

2. ESTIMADORES de MÍNIMA VARIANZA

Al construir un estimador pretendemos que sus estimaciones puntuales se aproximen lo más posible al valor del parámetro desconocido, que equivale a pretender que el ECM sea mínimo.

$$\begin{aligned} \text{ECM}(\hat{\theta}) &= E[(\hat{\theta} - \theta)^2] = E[\hat{\theta}^2 - 2\theta\hat{\theta} + \theta^2] = E[\hat{\theta}^2] - 2\theta E[\hat{\theta}] + \theta^2 = \\ &= (E[\hat{\theta}^2] - (E[\hat{\theta}])^2) + (E[\hat{\theta}]^2 - 2\theta E[\hat{\theta}] + \theta^2) = \\ &= V(\hat{\theta}) + (\hat{\theta} - \theta)^2 = \text{Varianza}(\hat{\theta}) + \text{sesgo}^2(\hat{\theta}) \end{aligned}$$

En muchas ocasiones no resulta sencillo minimizar el ECM, pero sí es fácil obtener estimadores insesgados ($b(\hat{\theta}) = 0$), de modo que dados dos estimadores insesgados del mismo parámetro será mejor el que tenga varianza mínima, es decir el que tenga menor ECM.

Por tanto, debemos ^{intentar} obtener un estimador, de entre todos los estimadores insesgados, que tenga varianza mínima
→ estimador insesgado de varianza mínima,

Si además se verifica que la varianza es mínima para todos los valores del parámetro, entonces el estimador recibe el nombre de estimador insesgado uniforme de mínima varianza (UMVUE)

Definición: Diremos que el estimador $\hat{\theta}_0$ es insesgado uniforme de mínima varianza (UMVUE) para el parámetro θ , si dado cualquier otro estimador insesgado $\hat{\theta}$ de él, se verifica:

$$\text{Var}(\hat{\theta}_0) \leq \text{Var}(\hat{\theta})$$

para todos los posibles valores de θ .

La utilización de la mínima varianza como criterio para elegir el mejor estimador es válido tanto para estimadores insesgados como para estimadores con el mismo sesgo.

También se utiliza el concepto de eficiencia relativa de un estimador respecto a otro $\hat{\theta}_1, \hat{\theta}_2$ insesg.

$$e(\hat{\theta}_1, \hat{\theta}_2) = \frac{ECM(\hat{\theta}_1)}{ECM(\hat{\theta}_2)} = \frac{V(\hat{\theta}_1)}{V(\hat{\theta}_2)}$$

La eficiencia relativa es siempre > 0 , porque es un cociente de cantidades positivas.

Una manera de obtener de un EMVUE es con la cota de Frechet - Cramér - Rao, que proporciona una cota inferior de la varianza del estimador.

Cota de Frechet - Cramér - Rao

Sea \mathcal{F} , población con $F(x, \theta) < P(x, \theta)$

Sea $X = (X_1, X_2, \dots, X_n)$ m.a.s. de tamaño n .

1º. Calculamos la función de verosimilitud conjunta de la muestra, $L(X, \theta) = f(x_1, \dots, x_n, \theta) = \prod f(x_i, \theta)$.

2º. Calculamos el logaritmo neperiano de la función de verosimilitud conjunta, $\ln L(X, \theta) = \ln \prod f(x_i, \theta) = \sum \ln f(x_i, \theta)$.

3º. Calculamos la derivada de esta expresión respecto al ~~valor de~~ parámetro θ .

$$\frac{\partial \ln L(X, \theta)}{\partial \theta}$$

4º. La cantidad de información de Fisher se define como $I(\theta) = E \left[\frac{\partial \ln L(X, \theta)}{\partial \theta} \right]^2$

Si se cumplen las condiciones de regularidad de Wolfowitz, la varianza del estimador está acotada inferiormente por $1/nI(\theta)$.

$$\text{Var}(\hat{\theta}) \geq \frac{1}{n E \left[\frac{\partial \ln L(X, \theta)}{\partial \theta} \right]^2} = \frac{1}{n I(\theta)}$$

las condiciones de regularidad de Fisher-Wolfowitz son:

- 1- El campo de variación, Θ , y por tanto la muestra X , de donde procede la muestra no depende de θ .
- 2- La función $\ln \mathcal{L}(X, \theta)$ admite al menos las dos primeras derivadas respecto a θ .
- 3- las operaciones de derivación e integración (suma por la v.a. discreta) son intercambiables.

observaciones:

- 01 $\rightarrow I(\hat{\theta}) \equiv$ cantidad de información de Fisher, representa la cantidad de información que la muestra proporciona sobre el parámetro.
Cuanto menor es $V(\hat{\theta})$, mayor es la información que proporciona $\hat{\theta}$ de θ .
- 02 \rightarrow La CCR depende del estimador concreto utilizado, a través de su sesgo y de la distrib. estudiada. En el caso de estimadores insesgados únicamente depende de la función de densidad poblacional y del tamaño muestral.
- 03 \rightarrow La CCR permite determinar si un estimador es eficiente ($V(\hat{\theta}) = CCR$), pero puede no existir.
- 03 \rightarrow El valor de la CCR no tiene ~~que~~ por qué ser cercano a 0, solamente mínimo.

3_ ESTIMADORES EFICIENTES

El inconveniente de la propiedad de insesgado es que solamente exige que el valor esperado del parámetro coincide con el estimador, $E[\hat{\theta}] = \theta$, pero no requiere que mucho, ni alguna estimación tome valores próximos al parámetro, que sería muy deseable.

Por eso, además de insesgado, se le pide que tenga la varianza pequeña.

Así, en un grupo de estimadores, el estimador más eficiente será el que tenga menor varianza.

Definición: $\hat{\theta}$ es eficiente si:

- 1- $\hat{\theta}$ es insesgado
- 2- $V(\hat{\theta}) = CCR$

Luego un estimador eficiente es un estimador insesgado uniforme de mínima varianza, UMVUE, cuya varianza coincide con el límite inferior, la Cota de Fisher - Cramér - Rao.

Pero puede que un UMVUE no sea eficiente pues, aunque tenga varianza mínima no alcanza el límite.

Definición: Se define la eficiencia absoluta de un estimador insesgado como el cociente entre la CCR y su varianza.

$$ef.a = \frac{CCR}{V(\hat{\theta})}$$

alcanzando su máximo (=1) cuando el estimador es eficiente.

Definición: $\hat{\theta}$ es asintóticamente eficiente si se verifica

$$\lim_{n \rightarrow \infty} V(\hat{\theta}) = CCR$$

- En $\xi \rightarrow N(\mu, \sigma)$, \bar{X} es eficiente de μ .
 s^2 no es eficiente de σ^2
- En $\xi \rightarrow B(m, p)$, $\hat{p} = \frac{\bar{X}}{m}$ es eficiente
- En $\xi \rightarrow \mathcal{P}(\lambda)$, $\hat{\lambda} = \bar{X}$ es eficiente

Propiedades de los estimadores eficientes:

PI \rightarrow El estimador eficiente es único.
Eficiente \Rightarrow Suficiente

4- ESTIMADORES ROBUSTOS

Diremos que un procedimiento estadístico es robusto si su comportamiento es relativamente insensible a desviaciones de las hipótesis iniciales sobre la que se había planteado el procedimiento.

Definición: Un estimador es robusto cuando pequeños cambios en las hipótesis de partida del procedimiento de estim. considerado no producen ^{variaciones} diferencias significativas en los resultados obtenidos.

Habitualmente, se considera una v.a. con cierta función de distribución, se extrae una $mas(n)$ y se obtiene un estimador $\hat{\theta}$ que depende de F .

Si la distrib. de poblacional es ligeramente distinta, la distrib. del estimador en el muestreo tb. lo será. Lo deseable es que no difiera mucho del primer estimador.

5- ESTIMADORES BAYESIANOS

En inferencia estadística clásica se supone que los parámetros poblacionales son constantes desconocidas, no aleatorios.

El enfoque inferencial bayesiano considera el parámetro desconocido θ como variable aleatoria, y tiene por tanto una distribución de probabilidad

$g(\theta) \rightarrow$ distribución a priori de θ .

Bajo la óptica bayesiana, la información proporcionada por la muestra X puede cambiar la idea del comportamiento probabilístico de $\theta \Rightarrow$ cambia la distribución de probabilidades de θ

$g(\theta/x) \rightarrow$ distrib. a posteriori de θ cuando se dispone de la información muestral X .

Aplicando el teo. de Bayes pueden determinarse la probab. a posteriori para cada valor de θ :

$$P(\theta = \theta_i / x) = \frac{P(\theta = \theta_i) \cdot P(X/\theta = \theta_i)}{\sum_i P(\theta = \theta_i) \cdot P(X/\theta = \theta_i)} \quad , \text{ caso discreto}$$

$$g(\theta/x) = \frac{g(\theta) \cdot f(X/\theta)}{\int_{\theta} g(\theta) \cdot f(X/\theta) d\theta} \quad , \text{ caso continuo}$$

El estimador de Bayes es una función de decisión (función de la información muestral X sobre el espacio de las posibles decisiones a adoptar) establecida sobre el espacio paramétrico θ , que produce el menor riesgo esperado.

mejor decisión de Bayes

El estimador será $\hat{\theta} = d^*(X)$ tal que

$$\min B(d) = \int_{\theta} \int_X \ell(\theta, d(X)) \cdot f(X/\theta) \cdot g(\theta) d\theta dX$$

donde

$B(d) \equiv$ riesgo de Bayes = valor esperado de la función de riesgo

$\ell(\theta, d(X)) \equiv$ función de pérdida

$R(\theta, d) \equiv$ función de riesgo = esperanza de la función de pérdida

El estimador de Bayes se puede obtener minimizando la expresión:

$$\min_{\theta/X} E \{ \ell(\theta, d(X)) \} = \int_{\theta} \ell(\theta, d(X)) g(\theta/X) d\theta$$

El estimador será aquel que

$$CN \rightarrow \frac{\partial E_{\theta/X} \{ \ell(\theta, d(X)) \}}{\partial d(X)} = 0 \Rightarrow \hat{\theta} = d^*(X)$$

$$CS \rightarrow \left. \frac{\partial^2 E_{\theta/X} \{ \ell(\theta, d(X)) \}}{\partial d^2(X)} \right|_{d(X)=d^*(X)} > 0$$

P1 \rightarrow Si la función de riesgo es constante respecto a θ , el estimador de Bayes coincide con el est. minimax

P2 \rightarrow Si la función de pérdida es cuadrática, el estm. de Bayes es el valor medio de la distrib. a posteriori.

P3 \rightarrow Si la función de pérdida es proporcional, $\ell(\theta, d(X)) = |\theta - d(X)|$ el estimador de Bayes es la mediana de la distrib. a posteriori de θ dado X .